



Lista Prática 2

Arthur Gonçalves de Souza - 221022794

Análise de Regressão Linear

Profa. Terezinha Ribeiro

Brasília

2025

Sumário



	Página
1 Introdução	1
2 Análise Descritiva	1
3 Seleção de covariáveis	9
4 Ajuste dos modelos	10
4.1 Modelo log(PBF) x Sexo e Esporte	10
4.2 Modelo PBF x LBM, BMI e Esporte	13
4.3 Modelo log(PBF) x LBM, BMI e Esporte	15
4.4 Modelo PBF x LBM, log(BMI) e Esporte	19
4.5 Modelo PBF x log(LBM), log(BMI) e Esporte	22
4.6 Modelo PBF x LBM, BMI e Esporte agrupado	24
4.7 Modelo PBF x BMI, Sexo e Esporte	26
4.8 Modelo log(PBF) x BMI, Sexo e Esporte	28
4.9 Modelo PBF x BMI, Sexo e Esporte agrupado	32
4.10 Modelo log(PBF) x BMI, Sexo e Esporte ajustado	34
4.11 Modelo PBF x LBM, BMI, Sexo e Esporte	36
4.12 Modelo PBF x LBM, BMI, Sexo e Esporte agrupado	38
5 Conclusão	40

1 Introdução


Este relatório possui como objetivo a aplicação de conceitos de regressão linear múltipla, apresentados durante o Semestre 2024.2 na disciplina Análise de Regressão Linear. Para a aplicação, trabalhou-se com dados de 202 atletas de alto desempenho do Instituto Australiano de Esporte (Australian Institute of Sport; AIS), com o objetivo de modelar o percentual de gordura corporal dos atletas (percentage body fat; PBF), em função das seguintes possíveis covariáveis: Sexo do atleta; Esporte praticado; Massa corporal magra, em kg (LBM); Índice de massa corporal, em kg por metro quadrado (BMI).

2 Análise Descritiva


Inicialmente, para compreender como a variável resposta e as possíveis covariáveis do estudo se comportam, foram elaborados histogramas e boxplots, além da análise das medidas descritivas. Após isso, verificou-se também como se dava a relação entre a resposta e as possíveis variáveis preditoras.




Histograma da massa corporal magra



Boxplot da massa corporal magra



Histograma do índice de massa corporal



Boxplot do índice de massa corporal





Tabela 1: Tabela de Medidas-resumo

Medida	PBF	LBM	BMI
Média	13,51	64,87	22,96
Desvio Padrão	6,19	13,07	2,86
Mínimo	5,63	34,36	16,75
1º Quartil	8,54	54,67	21,08
Mediana	11,65	63,03	22,72
3º Quartil	18,08	74,75	24,46
Máximo	35,52	106	34,42
Coef. de variação	0,46	0,2	0,12

Tratando das variáveis quantitativas inicialmente, é perceptível que a variável resposta, percentual de gordura corporal (PBF), apresenta uma distribuição assimétrica à direita, além de apresentar um valor discrepante acima do limite superior. Destaca-se também que a resposta apresenta um coeficiente de variação duas vezes maior que o das outras variáveis quantitativas, evidenciando assim uma maior dispersão dos dados com relação à média.


Abordando a massa corporal magra (LBM), percebe-se uma distribuição mais “próxima” da normal, sendo perceptível também a presença de um outlier acima do limite do superior, assim como foi percebido na análise da variável resposta.

Com relação ao índice de massa corporal (BMI), é notável também uma certa assimetria à direita, apesar de bem mais leve que a assimetria da variável resposta. Destaca-se bastante a presença de mais de 6 observações discrepantes acima do limite superior. Essa variável é a que apresenta menor coeficiente de variação dentre as quantitativas analisadas, e nota-se também a proximidade entre a média e a mediana.





Agora abordando as variáveis qualitativas, com relação ao esporte que cada atleta pratica, destaca-se o remo como o esporte mais praticado pelos atletas do Instituto, representando quase 20% do número total, seguido de atletismo e basquete. Em contrapartida, nota-se a ginástica como o esporte menos frequente no Instituto, apresentando apenas 4 atletas, referente à apenas 2% de todos atletas. Tratando do sexo dos atletas, percebe-se uma maior homogeneidade, com 50,5% (102) sendo homens e 49,5% (100) sendo mulheres.



Com o objetivo de entender a relação das covariáveis com a variável resposta, inicialmente foi calculado o coeficiente de correlação linear de Pearson para as três variáveis quantitativas, cujo resultado pode ser visualizado no gráfico abaixo:





Nota-se que não há nenhuma correlação linear forte da variável resposta com as possíveis co-variáveis quantitativas. Porém nota-se correlação linear positiva moderadamente forte, apresentando valor de 0,71, o que pode vir a ser um problema relacionado à multicolinearidade nos ajustes dos modelos.


Para visualizar melhor tais relações, foram elaborados os gráficos de dispersão abaixo, já considerando as variáveis originais e possíveis transformações logarítmicas que podem ser realizadas para linearizar mais tais relações.





Analisando a relação entre o Percentual de gordura corporal e a Massa corporal magra, percebe-se que realmente está bem distante de uma relação linear. Aplicando a transformação por log na resposta, foi obtida uma maior linearização da mesma, enquanto que aplicando o log apenas na covariável não trouxe a mesma melhoria. Por fim, a aplicação da transformação em ambas variáveis apresentou uma melhoria semelhante à transformação apenas na resposta.





Tratando da relação da resposta com o Índice de massa corporal (BMI), percebe-se uma relação fracamente linear, com uma leve melhora a partir das transformações, mas nenhuma sendo muita significativa.




Tabela 2: Tabela de medidas resumo por Sexo

Medida	Feminino	Masculino
Frequência	100	102
Média	17,85	9,25
Desvio Padrão	5,45	3,18
Mínimo	8,07	5,63
1º Quartil	13,24	6,97

Medida	Feminino	Masculino
Mediana	17,94	8,62
3º Quartil	21,36	10,01
Máximo	35,52	19,94

Observando a distribuição do percentual de gordura corporal por sexo, nota-se claramente uma tendência considerável, de que as mulheres apresentam esse percentual bem maior que os homens, com uma média de quase o dobro quando comparado ao sexo masculino, destacando-se ainda que até o 3º quartil do sexo masculino é menor que o feminino. Com relação à valores discrepantes, percebe-se mais de 5 valores acima do limite superior para o sexo masculino, enquanto há apenas um no sexo feminino.

Agora tratando do comportamento do percentual de gordura para cada esporte, houve uma abordagem diferente. Devido ao grande número de categorias nessa variável, o que com certeza impactará no número de parâmetros dos modelos que forem ajustados utilizando essa covariável, foi sugerido uma categorização de alguns esportes com base na média do percentual de gordura corporal, ocasionando nas seguintes categorias:

- Categoria 1: Netball, Rowing, BBall e Field;
- Categoria 2: WPolo, Tennis, Gym, Swim, TSprnt e T400m.

Nesse sentido, foram elaborados os gráficos e tabelas abaixo abordando a categorização original e a nova categorização:




Tabela 3: Tabela de medidas resumo por Esporte - Categoria 1

Medida	Netball	Rowing	BBall	Field
Frequência	23	37	25	19
Média	21,61	15,58	14,81	14,88
Desvio Padrão	5,73	5,79	6,52	5,92
Mínimo	11,29	6,96	7,06	6,43

Medida	Netball	Rowing	BBall	Field
1º Quartil	17,58	9,56	8,77	9,19
Mediana	21,32	16,58	15,07	13,97
3º Quartil	25,88	20,12	19,88	19,73
Máximo	35,52	25,16	28,83	24,88

Tabela 4: Tabela de medidas resumo por Esporte - Categoria 2

Medida	WPolo	Tennis	Gym	Swim	TSprnt	T400m
Frequência	17	11	4	22	15	29
Média	12,25	12,88	11,32	10,58	8,25	8,63
Desvio Padrão	3,64	4,78	2,03	3,43	2,05	3,1
Mínimo	7,82	6,26	9,1	6,16	5,8	5,63
1º Quartil	8,97	9,28	9,89	8,45	6,44	6,2
Mediana	11,63	11,5	11,36	9,3	7,52	6,99
3º Quartil	14,69	16,19	12,78	12,55	9,86	10,48
Máximo	19,17	20,86	13,46	18,48	11,64	16,2

Tabela 5: Tabela de medidas resumo por Esporte

Medida	Categoria 1	Categoria 2
Frequência	104	98
Média	16,6	10,22
Desvio Padrão	6,49	3,68
Mínimo	6,43	5,63
1º Quartil	9,84	7,04
Mediana	17,68	9,4
3º Quartil	21,3	12,08
Máximo	35,52	20,86

Analisando esporte por esporte, percebe-se que netball é o esporte que apresenta maior percentual média de gordura corporal, com uma média 21,61, bem próxima da mediana, 21,32. Por outro lado, temos Tspnt e T400m, ambos esportes relacionados com atletismo, como os que apresentam os menores percentuais médios de gordura entre os atletas, sendo os únicos que apresentam média menor que 10.

Abordando os esportes agrupados, nota-se que a categoria 1 apresenta 104 (51,5%) atletas, enquanto que a categoria 2 apresenta 98 (48,5%) atletas, representando assim porcentagens semelhantes de atletas. Por meio das medidas-resumo, é possível observar que a categoria 1 apresenta percentual médio de gordura corporal consideravelmente maior que a categoria 2, com cerca de 6% a mais. Tal discrepância é ainda maior ao se analisar a mediana, aumentando a diferença para 8%. Destaca-se ainda que o desvio padrão da categoria 1 é quase o dobro do desvio da categoria 2. Com relação os boxplots, percebe-se a presença um valor discrepante acima do limite superior para a categoria 2.

3 Seleção de covariáveis

Existem diversos procedimentos e critérios para a seleção de um sub-conjunto de covariáveis para serem incorporadas no modelo. Nosso objetivo consiste em escolher o modelo mais parcimonioso, isto é, selecionar covariáveis que conduzam um modelo de regressão ajustado com boa explicação e menor número de parâmetros possível. Para tal, foram utilizados três métodos de seleção de covariáveis:

- Método “passo atrás” (Backward), iniciando com o modelo contendo todas covariáveis;
- Método “passo a frente” (Frontward), iniciando com o modelo contendo apenas o intercepto;
- Método “passo a passo” (Stepwise), iniciando com o modelo contendo apenas o intercepto.

considerando o critério de informação de Akaike (AIC) como medida de avaliação dos modelos, os métodos concluíram que o modelo contendo todas as covariáveis, no caso a variável Esporte original em vez do Esporte agrupado, como o modelo mais adequado para explicar o percentual de gordura corporal dos atletas. Apesar da conclusão ter sido a mesma para os três, foi observado o passo a passo de cada um, considerando também possíveis transformações nas covariáveis, e chegou-se portanto os seguintes 12 modelos a serem ajustados:

Tabela 6: Modelos candidatos

Número	Resposta	Covariáveis
1	log(PBF)	Sexo e Esporte
2	PBF	LBM, BMI e Esporte
3	log(PBF)	LBM, BMI e Esporte
4	PBF	LBM, log(BMI) e Esporte
5	PBF	log(LBM), log(BMI) e Esporte
6	PBF	LBM, BMI e Esporte ajustado
7	PBF	BMI, Sexo e Esporte
8	log(PBF)	BMI, Sexo e Esporte
9	PBF	BMI, Sexo e Esporte ajustado
10	log(PBF)	BMI, Sexo e Esporte ajustado
11	PBF	LBM, BMI, Sexo e Esporte
12	PBF	LBM, BMI, Sexo e Esporte ajustado

4 Ajuste dos modelos

4.1 Modelo $\log(\text{PBF}) \times \text{Sexo e Esporte}$

Tabela 7: Ajuste do modelo $\log(\text{PBF}) \times \text{Sexo e Esporte}$


Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	2,490324	0,048969	50,8549	< 0,0001
SexoMasculino	-0,626372	0,037914	-16,5207	< 0,0001
EsporteBBall	0,405922	0,063339	6,4087	< 0,0001
EsporteField	0,520398	0,068258	7,624	< 0,0001
EsporteGym	-0,076280	0,125572	-0,6075	0,5443
EsporteNetball	0,548386	0,068726	7,9793	< 0,0001
EsporteRowing	0,434437	0,057933	7,4989	< 0,0001
EsporteSwim	0,191875	0,065394	2,9341	0,0038
EsporteTennis	0,228698	0,082469	2,7731	0,0061
EsporteTSprnt	0,050325	0,073674	0,6831	0,4954
EsporteWPolo	0,601851	0,07209	8,3486	< 0,0001
R^2	0,751500			
R^2 Ajustado	0,738500			

Por meio da tabela acima, temos que o modelo apresentou um ajuste adequado, considerando apenas dois coeficientes não significativos, a um nível de 5% de significância, relacionados aos esportes Gym e TSprnt, que nesse contexto não apresentam diferença significativa quando troca-se do esporte referência do modelo, nesse caso T400m, para esses outros dois esportes. Nota-se ainda que o modelo explica mais de 75% da variabilidade dos dados, apresentando $R^2 = 0,7515$.


4.1.1 Análise das suposições

Ao ajustar um modelo, é importante verificar se as suposições necessárias para sua inferência estão sendo cumpridas. Nesse caso, para verificar a normalidade, homoscedasticidade e não-correlação dos erros, foram elaborados os seguintes gráficos:


Envelope Dist. Normal




Envelope Dist. T



Resíduos x Valores ajustados



Resíduos x Índices



Com relação à normalidade dos erros, não é perceptível nenhum grande desvio de tal suposição. Abordando a homoscedasticidade, nota-se uma certa tendência crescente da variância à medida que os valores ajustados aumentam, indicando assim um desvio dessa suposição. Destacam-se ainda os pontos 36 e 162 como possíveis aberrantes. Tratando da não-correlação dos erros, não é perceptível nenhum tipo de tendência pelo gráfico dos resíduos studentizados pelos índices, indicando assim que não há evidências de desvio de tal suposição.

Para gerar mais evidências para tais decisões, optou-se por aplicar um teste para cada uma delas, sendo o primeiro, o teste Shapiro-Wilk, que avalia a aderência dos resíduos studentizados à distribuição Normal, o segundo, o teste Breusch-Pagan, que analisa se as variâncias dos resíduos studentizados são iguais, e por último o teste Durbin-Watson, que avalia a presença de correlação entre os resíduos studentizados. Esses testes possuem as seguintes hipóteses

nula:

Tabela 8: Testes de hipóteses para as suposições

Teste	Hipótesese nula
Shapiro-Wilk	Os resíduos Studentizados seguem distribuição normal padrão
Breusch-Pagan	As variâncias dos resíduos Studentizados são iguais
Durbin-Watson	Os resíduos Studentizados são não-correlacionados

Tabela 9: Testes de hipóteses aplicados

Teste	Suposições	P-valor	Decisão
Shapiro-Wilk	Normalidade	0,8156	Não rejeita hipótese nula
Breusch-Pagan	Homoscedasticidade	0,0018	Rejeita hipótese nula
Durbin-Watson	Não-Correlação	0,9309	Não rejeita hipótese nula

A partir dos resultados obtidos pelos testes, e também pelo que foi percebido nos gráficos, concluímos que esse modelo ajustado não cumpre com a suposição de homoscedasticidade, sendo evidenciado ainda pelo p-valor = 0,0018 do teste Breusch-Pagan, que rejeita a hipótese nula à um nível de significância de 5%.

Além dessas suposições citadas anteriormente, é importante verificar também se existem indícios de multicolinearidade quase exata no modelo. Essa condição indica que uma ou mais covariáveis podem ser escritas como combinação linear das outras covariáveis no modelo, impactando assim em uma redundância no modelo.

Para verificar tal condição, é avaliado o fator de inflação da variância (VIF), que é definido por:

$$VIF_j = \frac{1}{1 - R_j^2}, \quad j = 1, \dots, k$$

Onde: - k é o número de covariáveis desconsiderando o intercepto - R_j^2 é o coeficiente de determinação associado à j-ésima regressão auxiliar.

Nesse contexto, temos que valores de VIF maiores que 5 ($R_j^2 = 0,8$) são uma indicação de que o coeficiente associado à covariável x_j e seu respectivo erro-padrão serão mal estimados. Em outras palavras, teremos indícios de multicolinearidade quase exata.

Tabela 10: Fator de inflação da variância para as covariáveis do modelo

	VIF
Sexo	1,357
Esporte	1,357

A partir dos valores de VIF obtidos, não há indícios de multicolinearidade quase exata.

Portanto, concluímos aqui a análise do modelo 1, $\log(\text{PBF}) \sim \text{Sexo} + \text{Esporte}$, visto que o mesmo não cumpre com as suposições necessárias para seu procedimento inferencial.





4.2 Modelo PBF x LBM, BMI e Esporte

Tabela 11: Ajuste do modelo PBF x LBM, BMI e Esporte

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	-1,398233	2,042604	-0,6845	0,4945
LBM	-0,485362	0,025681	-18,8999	< 0,0001
BMI	1,854596	0,124944	14,8434	< 0,0001
EsporteBBall	8,057288	0,807214	9,9816	< 0,0001
EsporteField	2,316485	1,068885	2,1672	0,0315
EsporteGym	-2,867277	1,58248	-1,8119	0,0716
EsporteNetball	7,728274	0,855737	9,0311	< 0,0001
EsporteRowing	5,739813	0,759322	7,5591	< 0,0001
EsporteSwim	2,146330	0,840172	2,5546	0,0114
EsporteTennis	2,431932	1,022453	2,3785	0,0184
EsporteTSprnt	-0,919340	0,936732	-0,9814	0,3276
EsporteWPolo	5,127098	0,956674	5,3593	< 0,0001
R ²	0,796100			
R ² Ajustado	0,784300			

Por meio da tabela acima, temos que o modelo apresentou um ajuste adequado, considerando apenas 3 coeficientes não significativos, a um nível de 5% de significância, nesse caso relacionados ao intercepto, e assim como no modelo anterior, aos esportes Gym e TSprnt, que nesse contexto não apresentam diferença significativa quando troca-se do esporte referência do modelo, nesse caso T400m, para esses outros dois esportes. A não significância do intercepto indica que o modelo poderia ser ajustado sem o mesmo, mas será mantido por questões de praticidade. Destaca-se ainda que o modelo explica mais de 79% da variabilidade dos dados, apresentando $R^2 = 0,7961$.

4.2.1 Análise das suposições



Com relação à normalidade dos erros, não é perceptível nenhum grande desvio de tal suposição. Abordando a homoscedasticidade, nota-se novamente uma certa tendência crescente da variância à medida que os valores ajustados aumentam, apesar de menos evidente que o modelo, apresentando também indícios de desvio dessa suposição. Destacam-se ainda os pontos 11 e 184 como possíveis aberrantes, ou seja, observações que receberam um ajuste ruim. Tratando da não-correlação dos erros, não é perceptível nenhum tipo de tendência pelo gráfico dos resíduos studentizados pelos índices, que aparentam se distribuírem de forma aleatória, indicando assim que não há evidências de desvio de tal suposição.

Tabela 12: Testes de hipóteses aplicados

Teste	Suposições	P-valor	Decisão
Shapiro-Wilk	Normalidade	0,3613	Não rejeita hipótese nula
Breusch-Pagan	Homoscedasticidade	0,0148	Rejeita hipótese nula
Durbin-Watson	Não-Correlação	0,1800	Não rejeita hipótese nula

A partir dos resultados obtidos pelos testes, e também pelo que foi percebido nos gráficos, concluímos que esse modelo ajustado não cumpre com a suposição de homoscedasticidade, sendo evidenciado ainda pelo p-valor = 0,0148 do teste Breusch-Pagan, que rejeita a hipótese nula à um nível de significância de 5%.

Tabela 13: Fator de inflação da variância para as covariáveis do modelo

	VIF
LBM	2,740
BMI	3,115
Esporte	2,400

A partir dos valores de VIF obtidos, não há indícios de multicolinearidade quase exata no modelo 2.

Portanto, concluímos aqui a análise do modelo 2, PBF x LBM, BMI e Esporte, visto que o mesmo não cumpre com as suposições necessárias para seu procedimento inferencial.

4.3 Modelo $\log(\text{PBF}) \times \text{LBM}$, BMI e Esporte


Tabela 14: Ajuste do modelo $\log(\text{PBF}) \times \text{LBM}$, BMI e Esporte

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	1,535902	0,150249	10,2224	< 0,0001
LBM	-0,035868	0,001889	-18,9876	< 0,0001
BMI	0,128582	0,009191	13,9906	< 0,0001
EsporteBBall	0,646099	0,059377	10,8814	< 0,0001
EsporteField	0,280748	0,078625	3,5707	0,0005
EsporteGym	-0,116541	0,116403	-1,0012	0,318
EsporteNetball	0,563787	0,062946	8,9567	< 0,0001
EsporteRowing	0,503292	0,055854	9,0109	< 0,0001
EsporteSwim	0,243648	0,061801	3,9425	0,0001
EsporteTennis	0,258974	0,075209	3,4434	0,0007
EsporteTSprnt	-0,041505	0,068904	-0,6024	0,5477
EsporteWPolo	0,507803	0,070371	7,2161	< 0,0001
R ²	0,793300			
R ² Ajustado	0,781400			

Por meio da tabela acima, temos que o modelo considerando o logarítmico da resposta apresentou um ajuste adequado, considerando apenas dois coeficientes não significativos, a um

nível de 5% de significância, relacionados novamente aos esportes Gym e TSprnt, que nesse contexto não apresentam diferença significativa quando troca-se do esporte referência do modelo, T400m, para esses outros dois esportes. Ao contrário do modelo anterior, que considerou o intercepto não significativo, agora ele foi considerado significativo, apresentando uma grande diminuição da estimativa do erro padrão associado ao mesmo. Nota-se ainda que o modelo explica mais de 79% da variabilidade dos dados, apresentando $R^2 = 0,7933$.

4.3.1 Análise das suposições



Com relação à normalidade dos erros, não é perceptível nenhum grande desvio de tal suposição, apresentando praticamente todos os pontos dentro do envelope. Abordando a ho-

moscedasticidade, não percebe-se agora nenhuma grande tendência da variância em relação aos valores ajustados, não apresentando portanto fortes indícios de desvio dessa suposição. Destaca-se ainda o ponto 133 como possível aberrante, ou seja, provavelmente essa observação recebeu um ajuste ruim. Tratando da não-correlação dos erros, nota-se uma leve tendência crescente no gráfico, mas não o suficiente para indicar indícios de desvio de tal suposição.

Tabela 15: Testes de hipóteses aplicados

Teste	Suposições	P-valor	Decisão
Shapiro-Wilk	Normalidade	0,9006	Não rejeita hipótese nula
Breusch-Pagan	Homoscedasticidade	0,0229	Rejeita hipótese nula
Durbin-Watson	Não-Correlação	0,0252	Rejeita hipótese nula

Analisando os resultados apresentados para os testes de hipóteses, sob um nível de significância de 5%, tem-se que foram rejeitadas as hipóteses nulas relacionadas à homoscedasticidade e não-correlação. Apesar de tais resultados, pelo que pôde ser observado nos gráficos, decidiu-se por assumir que não há desvios significativos dessas suposições no modelo.

Tabela 16: Fator de inflação da variância para as covariáveis do modelo

	VIF
LBM	2,740
BMI	3,115
Esporte	2,400


Por meio dos resultados obtidos pelo VIF de cada covariável, também não há indícios de multicolinearidade quase exata no modelo 3.

Sendo assim, parte-se então para a análise de alavancagem e influência do modelo

4.3.2 Análise de alavancagem e influência

Pontos de alavanca são pontos que possuem peso desproporcional no próprio valor ajustado, geralmente tendo essa desproporcionalidade causada por possuírem uma inconformidade em relação ao valor de alguma das covariáveis. Além disso, eles também podem exercer influência atípica nas estimativas dos coeficientes da regressão. Para identificar esses pontos, analisamos suas medidas de alavancagem, como pode-se visualizar no gráfico abaixo:


Alavancagem




A partir do gráfico, nota-se que os pontos 97, 98, 99 e 100 podem ser classificados como possíveis pontos de alavanca, devendo-se então realizar uma investigação sobre os mesmos.

Já em relação à influência, são classificadas como influentes aquelas observações que exercem influência desproporcional nas estimativas dos parâmetros do modelo e podem causar mudança inferencial. Destaca-se que usualmente um ponto influente é aberrante e/ou alavanca.

DFFITS



Distâncias de Cook



Em relação à influência, desta vez foi possível observar, em ambos gráficos, os pontos 96 e 160 como possíveis pontos influentes, devendo-se então realizar uma investigação sobre os mesmos.

4.3.3 Investigação dos pontos atípicos

A partir das técnicas aplicadas anteriormente, foram observados os pontos 96, 97, 98, 99, 100 e 133, como possíveis pontos atípicos, e portanto, estes serão investigados por meio do ajuste do modelo retirando os mesmos.

Tabela 17: Ajuste do modelo $\log(\text{PBF}) \times \text{BMI}$, Sexo e Esporte retirando os pontos 96, 97, 98, 99, 100 e 133

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	1,622863	0,146516	11,0764	< 0,0001
LBM	-0,037136	0,001847	-20,1039	< 0,0001
BMI	0,127973	0,008891	14,3937	< 0,0001
EsporteBBall	0,631043	0,057475	10,9794	< 0,0001
EsporteField	0,307560	0,076052	4,0441	0,0001
EsporteNetball	0,559329	0,060641	9,2236	< 0,0001
EsporteRowing	0,515165	0,053864	9,5641	< 0,0001
EsporteSwim	0,256141	0,059577	4,2993	< 0,0001
EsporteTennis	0,310083	0,074967	4,1362	0,0001
EsporteTSprnt	-0,031145	0,066389	-0,4691	0,6395
EsporteWPolo	0,532081	0,068002	7,8245	< 0,0001
R ²	0,812100			
R ² Ajustado	0,802000			

Analisando o modelo ajustado com a retirada dos pontos atípicos, não percebe-se nenhuma mudança considerável de estimativas nem de significância, além do caso específico do esporte gym, que só apresentava 4 atletas e todos foram considerados influentes e portanto retirados na investigação, o que não é algo tão prejudicial, visto que a estimativa do coeficiente associado ao gym já havia sido considerado como não significante. Ademais, a maior mudança relativa de estimativa foi a do coeficiente associado ao esporte Tennis, que apresentou uma mudança relativa de 19%, saindo de 0,25 para 0,31.

4.4 Modelo PBF x LBM, $\log(\text{BMI})$ e Esporte



Tabela 18: Ajuste do modelo PBF x LBM, $\log(\text{BMI})$ e Esporte


Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	-95,426095	8,047749	-11,8575	< 0,0001
LBM	-0,487839	0,025802	-18,9071	< 0,0001
$\log(\text{BMI})$	43,781970	2,951456	14,834	< 0,0001
EsporteBBall	7,843409	0,808101	9,706	< 0,0001
EsporteField	2,909068	1,049352	2,7723	0,0061
EsporteGym	-2,093756	1,582012	-1,3235	0,1873
EsporteNetball	7,513228	0,860985	8,7263	< 0,0001
EsporteRowing	5,425836	0,765706	7,0861	< 0,0001
EsporteSwim	1,858703	0,843608	2,2033	0,0288
EsporteTennis	2,502947	1,022417	2,4481	0,0153
EsporteTSprnt	-1,189675	0,94014	-1,2654	0,2073

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
EsporteWPolo	4,853147	0,960543	5,0525	< 0,0001
R^2	0,796000			
R^2 Ajustado	0,784200			

Por meio da tabela acima, temos que o modelo considerando o logarítmico da covariável BMI apresentou um ajuste adequado, novamente sendo considerado apenas dois coeficientes não significativos, a um nível de 5% de significância, relacionados novamente aos esportes Gym e TSprnt, que nesse contexto não apresentam diferença significativa quando troca-se do esporte referência do modelo, T400m, para esses outros dois esportes. Nota-se ainda que o modelo explica mais de 79% da variabilidade dos dados, apresentando $R^2 = 0,796$.

4.4.1 Análise das suposições





Com relação à normalidade dos erros, não é perceptível nenhum grande desvio de tal suposição. Abordando a homoscedasticidade, nota-se agora uma moderada tendência crescente da variância à medida que os valores ajustados aumentam, bem mais evidente que o modelo anterior, apresentando indícios de desvio dessa suposição. Destacam-se ainda os pontos 11 e 184 como possíveis aberrantes, ou seja, observações que receberam um ajuste ruim, assim como aconteceu no modelo considerada as tais variáveis na forma original. Tratando da não-correlação dos erros, não é perceptível nenhum tipo de tendência pelo gráfico dos resíduos studentizados pelos índices, que aparentam se distribuírem de forma aleatória, indicando assim que não há evidências de desvio de tal suposição.

Tabela 19: Testes de hipóteses aplicados

Teste	Suposições	P-valor	Decisão
Shapiro-Wilk	Normalidade	0,1726	Não rejeita hipótese nula
Breusch-Pagan	Homoscedasticidade	0,0124	Rejeita hipótese nula
Durbin-Watson	Não-Correlação	0,0675	Não rejeita hipótese nula

A partir dos resultados obtidos pelos testes, e também pelo que foi percebido nos gráficos, concluímos que esse modelo ajustado não cumpre com a suposição de homoscedasticidade, sendo evidenciado ainda pelo p-valor = 0,0124 do teste Breusch-Pagan, que rejeita a hipótese nula à um nível de significância de 5%.

Tabela 20: Fator de inflação da variância para as covariáveis do modelo

	VIF
LBM	2,764
log(BMI)	3,092
Esporte	2,313

A partir dos valores de VIF obtidos, não há indícios de multicolinearidade quase exata no modelo 4.

Portanto, concluímos aqui a análise do modelo 4, PBF x LBM, log(BMI) e Esporte, visto que o mesmo não cumpre com as suposições necessárias para seu procedimento inferencial.





4.5 Modelo PBF x log(LBM), log(BMI) e Esporte

Tabela 21: Ajuste do modelo PBF x log(LBM), log(BMI) e Esporte

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	5,598047	7,012468	0,7983	0,4257
log(LBM)	-31,995640	1,760702	-18,1721	< 0,0001
log(BMI)	43,891260	3,050414	14,3886	< 0,0001
EsporteBBall	7,650476	0,827776	9,2422	< 0,0001
EsporteField	2,479658	1,07848	2,2992	0,0226
EsporteGym	-5,458757	1,668698	-3,2713	0,0013
EsporteNetball	7,378476	0,886698	8,3213	< 0,0001
EsporteRowing	5,363597	0,785688	6,8266	< 0,0001
EsporteSwim	1,897152	0,865527	2,1919	0,0296
EsporteTennis	2,061231	1,051336	1,9606	0,0514
EsporteTSprnt	-1,022940	0,964438	-1,0607	0,2902
EsporteWPolo	4,879361	0,985827	4,9495	< 0,0001
R ²	0,785300			
R ² Ajustado	0,772900			

Por meio da tabela acima, temos que o modelo considerando os logarítmicos das covariáveis LBM e BMI apresentou um ajuste adequado, considerando três coeficientes como não significativos a um nível de 5% de significância, relacionados novamente ao intercepto e os esportes TSprnt e Tennis, que nesse contexto não apresentam diferença significativa quando troca-se do esporte referência do modelo, T400m, para esses outros dois esportes. Curiosamente nesse modelo destaca-se que a variável Gym foi considerada significativa, comportamento que não se aconteceu nos modelos anteriores. Nota-se ainda que o modelo explica mais de 78% da variabilidade dos dados, apresentando $R^2 = 0,7853$.

4.5.1 Análise das suposições



Com relação à normalidade dos erros, agora percebe-se alguns pontos “saindo” do envelope, e devido à pequena quantidade de pontos, não considera-se como um grande indício de desvio de tal suposição. Abordando a homoscedasticidade, nota-se novamente uma moderada tendência crescente da variância à medida que os valores ajustados aumentam, ainda mais evidente que o modelo anterior, apresentando indícios de desvio dessa suposição. Destacam-se ainda os pontos 11 e 29 como possíveis aberrantes, ou seja, observações que receberam um ajuste ruim. Tratando da não-correlação dos erros, não é perceptível nenhum tipo de tendência pelo gráfico dos resíduos studentizados pelos índices, que aparentam se distribuírem de forma aleatória, indicando assim que não há evidências de desvio de tal suposição.

Tabela 22: Testes de hipóteses aplicados

Teste	Suposições	P-valor	Decisão
Shapiro-Wilk	Normalidade	0,5601	Não rejeita hipótese nula
Breusch-Pagan	Homoscedasticidade	0,0042	Rejeita hipótese nula
Durbin-Watson	Não-Correlação	0,0882	Não rejeita hipótese nula

A partir dos resultados obtidos pelos testes, e também pelo que foi percebido nos gráficos, concluímos que esse modelo ajustado não cumpre com a suposição de homoscedasticidade, sendo evidenciado ainda pelo p-valor = 0,0042 do teste Breusch-Pagan, que rejeita a hipótese nula à um nível de significância de 5%.

Tabela 23: Fator de inflação da variância para as covariáveis do modelo

	VIF
log(LBM)	2,950
log(BMI)	3,138
Esporte	2,459

A partir dos valores de VIF obtidos, não há indícios de multicolinearidade quase exata no modelo 5.

Portanto, concluímos aqui a análise do modelo 5, PBF x log(LBM), log(BMI) e Esporte, visto que o mesmo não cumpre com as suposições necessárias para seu procedimento inferencial.





4.6 Modelo PBF x LBM, BMI e Esporte agrupado

Tabela 24: Ajuste do modelo PBF x LBM, BMI e Esporte ajustado

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	7,673775	2,184668	3,5126	0,0005
LBM	-0,440808	0,027262	-16,1695	< 0,0001
BMI	1,605481	0,128618	12,4826	< 0,0001
EsportesCategoria 2	-4,998007	0,517225	-9,6631	< 0,0001
R ²	0,684900			
R ² Ajustado	0,680100			

Por meio da tabela acima, temos que o modelo considerando o esporte agrupado apresentou um ajuste adequado, considerando todos os coeficientes como significativos a um nível de 5% de significância, nesse caso apresentando apenas 4 coeficientes, sendo um grande melhoria com relação aos modelos apresentados anteriormente. Nota-se ainda que o modelo explica mais de 68% da variabilidade dos dados, apresentando $R^2 = 0,6849$.

4.6.1 Análise das suposições



Com relação à normalidade dos erros, agora percebe-se uma grande quantidade de pontos “saindo” do envelope, e portanto considera-se como um indício de desvio de tal suposição. Abordando a homoscedasticidade, nota-se também uma certa tendência crescente da variância à medida que os valores ajustados aumentam, não tão evidente como o modelo anterior, levando a não considerar como um grande indício de desvio dessa suposição. Destacam-se ainda os pontos 56 e 184 como possíveis aberrantes, ou seja, observações que receberam um ajuste ruim. Tratando da não-correlação dos erros, percebe-se também uma maior tendência pelo gráfico dos resíduos studentizados pelos índices, que não aparentam se distribuírem de forma aleatória, indicando assim que há possivelmente evidências de desvio de tal suposição.

Tabela 25: Testes de hipóteses aplicados

Teste	Suposições	P-valor	Decisão
Shapiro-Wilk	Normalidade	0,0015	Rejeita hipótese nula
Breusch-Pagan	Homoscedasticidade	0,2448	Não rejeita hipótese nula
Durbin-Watson	Não-Correlação	<0,001	Rejeita hipótese nula

A partir dos resultados obtidos pelos testes, e também pelo que foi percebido nos gráficos, concluímos que esse modelo ajustado não cumpre com a suposição de normalidade e não-correlação.

Tabela 26: Fator de inflação da variância para as covariáveis do modelo

	VIF
LBM	2,082
BMI	2,225
Esportes	1,101

A partir dos valores de VIF obtidos, não há indícios de multicolinearidade quase exata no modelo 6.

Portanto, concluímos aqui a análise do modelo 6, PBF x LBM, BMI e Esporte agrupado, visto que o mesmo não cumpre com as suposições necessárias para seu procedimento inferencial.

4.7 Modelo PBF x BMI, Sexo e Esporte


Tabela 27: Ajuste do modelo PBF x BMI, Sexo e Esporte

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	-5,654348	2,086923	-2,7094	0,0074
BMI	0,972188	0,101432	9,5846	< 0,0001
SexoMasculino	-9,470184	0,505232	-18,7442	< 0,0001
EsporteBBall	3,367898	0,811422	4,1506	0,0001
EsporteField	-0,258016	1,095575	-0,2355	0,8141
EsporteGym	-1,033065	1,573646	-0,6565	0,5123
EsporteNetball	5,448013	0,903663	6,0288	< 0,0001
EsporteRowing	2,231477	0,790445	2,8231	0,0053
EsporteSwim	-0,466654	0,848442	-0,55	0,583
EsporteTennis	1,455955	1,033884	1,4082	0,1607
EsporteTSprnt	-1,412667	0,94195	-1,4997	0,1353
EsporteWPolo	3,583829	0,953152	3,76	0,0002
R ²	0,793900			
R ² Ajustado	0,782000			

Por meio da tabela acima, temos que o modelo apresentou um ajuste adequado, porém nesse caso foram considerados apenas 5 coeficientes associados à esportes como não significativos a um nível de 5% de significância, relacionados agora aos esportes Field, Gym, Swim, Tennis e

TSprnt, que nesse contexto não apresentam diferença significativa quando troca-se do esporte referência do modelo, T400m, para esses outros esportes. Nota-se ainda que o modelo explica mais de 79% da variabilidade dos dados, apresentando $R^2 = 0,7939$.

4.7.1 Análise das suposições



Com relação à normalidade dos erros, percebe-se alguns pontos “saindo” do envelope, mas devido à pequena quantidade, não considera-se como um grande indício de desvio de tal suposição. Abordando a homoscedasticidade, nota-se agora uma grande tendência crescente da variância à medida que os valores ajustados aumentam, ainda mais evidente que os modelos vistos anteriormente, apresentando indícios de desvio dessa suposição. Destacam-se

ainda os pontos 56 e 160 como possíveis aberrantes, ou seja, observações que receberam um ajuste ruim. Tratando da não-correlação dos erros, não é perceptível nenhum tipo de tendência pelo gráfico dos resíduos studentizados pelos índices, que aparentam se distribuírem de forma aleatória, indicando assim que não há evidências de desvio de tal suposição.

Tabela 28: Testes de hipóteses aplicados

Teste	Suposições	P-valor	Decisão
Shapiro-Wilk	Normalidade	0,2375	Não rejeita hipótese nula
Breusch-Pagan	Homoscedasticidade	0,0066	Rejeita hipótese nula
Durbin-Watson	Não-Correlação	0,2990	Não rejeita hipótese nula

A partir dos resultados obtidos pelos testes, e também pelo que foi percebido nos gráficos, concluímos que esse modelo ajustado não cumpre com a suposição de homoscedasticidade, sendo evidenciado ainda pelo p-valor = 0,0066 do teste Breusch-Pagan, que rejeita a hipótese nula à um nível de significância de 5%.

Tabela 29: Fator de inflação da variância para as covariáveis do modelo

	VIF
BMI	2,031
Sexo	1,543
Esporte	2,447

A partir dos valores de VIF obtidos, não há indícios de multicolinearidade quase exata no modelo 7.

Portanto, concluímos aqui a análise do modelo 7, PBF x BMI, Sexo e Esporte, visto que o mesmo não cumpre com as suposições necessárias para seu procedimento inferencial.

4.8 Modelo log(PBF) x BMI, Sexo e Esporte



Tabela 30: Ajuste do modelo log(PBF) x BMI, Sexo e Esporte


Coefficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	1,187544	0,135126	8,7884	< 0,0001
BMI	0,066231	0,006568	10,0846	< 0,0001
SexoMasculino	-0,740867	0,032713	-22,6474	< 0,0001
EsporteBBall	0,289453	0,052539	5,5093	< 0,0001
EsporteField	0,071511	0,070937	1,0081	0,3147
EsporteGym	-0,000107	0,101892	-0,001	0,9992
EsporteNetball	0,364961	0,058511	6,2375	< 0,0001
EsporteRowing	0,227320	0,05118	4,4416	< 0,0001
EsporteSwim	0,043052	0,054936	0,7837	0,4342
EsporteTennis	0,175267	0,066943	2,6182	0,0096
EsporteTSprnt	-0,079500	0,06099	-1,3035	0,194
EsporteWPolo	0,398676	0,061715	6,4599	< 0,0001
R ²	0,838100			

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
R^2 Ajustado	0,828800			

Por meio da tabela acima, temos que o modelo considerando o logarítmico da resposta apresentou um ajuste adequado, considerando agora quatro coeficientes não significativos a um nível de 5% de significância, relacionados aos esportes Field, Gym, Swim e TSprnt, que nesse contexto não apresentam diferença significativa quando troca-se do esporte referência do modelo, T400m, para esses outros dois esportes. Nota-se ainda que o modelo explica mais de 83% da variabilidade dos dados, apresentando $R^2 = 0,8381$.

4.8.1 Análise das suposições





Com relação à normalidade dos erros, não é perceptível nenhum grande desvio de tal suposição, apresentando praticamente todos os pontos dentro do envelope. Abordando a homoscedasticidade, não percebe-se agora nenhuma grande tendência da variância em relação aos valores ajustados, não apresentando portanto indícios de desvio dessa suposição. Destaca-se ainda o pontos 160 e 184 como possíveis aberrantes, ou seja, provavelmente essa observação recebeu um ajuste ruim. Tratando da não-correlação dos erros, nota-se uma leve tendência crescente no gráfico, mas não o suficiente para indicar indícios de desvio de tal suposição.

Tabela 31: Testes de hipóteses aplicados

Teste	Suposições	P-valor	Decisão
Shapiro-Wilk	Normalidade	0,9561	Não rejeita hipótese nula
Breusch-Pagan	Homoscedasticidade	0,1223	Não rejeita hipótese nula
Durbin-Watson	Não-Correlação	0,3125	Não rejeita hipótese nula

Analisando os resultados apresentados para os testes de hipóteses, sob um nível de significância de 5%, tem-se que nenhuma hipótese nula foi rejeitada, indicando que não há desvios significativos dessas suposições no modelo.

Tabela 32: Fator de inflação da variância para as covariáveis do modelo


	VIF
BMI	2,031
Sexo	1,543
Esporte	2,447

Por meio dos resultados obtidos pelo VIF de cada covariável, também não há indícios de multicolinearidade quase exata no modelo 8.

Sendo assim, parte-se então para a análise de alavancagem e influência do modelo


4.8.2 Análise de alavancagem e influência

Alavancagem




A partir do gráfico, nota-se que os pontos 97, 98, 99 e 100 podem ser classificados como possíveis pontos de alavanca, devendo-se então realizar uma investigação sobre os mesmos.

DFFITS



Distâncias de Cook



Em relação à influência, desta vez foi possível observar, em ambos gráficos, os pontos 96 e 160 como possíveis pontos influentes, devendo-se então realizar uma investigação sobre os mesmos.

4.8.3 Investigação dos pontos atípicos

A partir das técnicas aplicadas anteriormente, foram observados os pontos 96, 97, 98, 99, 100, 160 e 184, como possíveis pontos atípicos, e portanto, estes serão investigados por meio do ajuste do modelo retirando os mesmos.

Tabela 33: Ajuste do modelo $\log(\text{PBF}) \times \text{BMI}$, Sexo e Esporte retirando os pontos 96, 97, 98, 99, 100, 160 e 184

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	1,151895	0,130914	8,7989	< 0,0001
BMI	0,068016	0,00636	10,6938	< 0,0001
SexoMasculino	-0,743063	0,031098	-23,894	< 0,0001
EsporteBBall	0,286440	0,049932	5,7366	< 0,0001
EsporteField	0,089346	0,067616	1,3214	0,188
EsporteNetball	0,360571	0,055614	6,4835	< 0,0001
EsporteRowing	0,221932	0,048727	4,5546	< 0,0001
EsporteSwim	0,039070	0,052245	0,7478	0,4555
EsporteTennis	0,218180	0,065803	3,3157	0,0011
EsporteTSprnt	-0,083098	0,057986	-1,4331	0,1535
EsporteWPolo	0,361601	0,059804	6,0465	< 0,0001
R ²	0,856500			
R ² Ajustado	0,848700			

Analisando o modelo ajustado com a retirada dos pontos atípicos, novamente não percebe-se nenhuma mudança considerável de estimativas nem de significância, além do caso específico do esporte gym, que só apresentava 4 atletas e todos foram considerados influentes e portanto retirados na investigação, o que não é algo tão prejudicial, visto que a estimativa do coeficiente associado ao gym já era bem próxima de 0. Ademais, a maior mudança relativa de estimativa também foi a do coeficiente associado ao esporte Tennis, que apresentou uma mudança relativa de 24%, saindo de 0,17 para 0,21.





4.9 Modelo PBF x BMI, Sexo e Esporte agrupado

Tabela 34: Ajuste do modelo $\text{PBF} \times \text{BMI}$, Sexo e Esporte agrupado

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	0,115041	2,183588	0,0527	0,958
BMI	0,846485	0,094513	8,9563	< 0,0001
SexoMasculino	-9,546212	0,53971	-17,6877	< 0,0001
EsportesCategoria 2	-2,512790	0,52832	-4,7562	< 0,0001
R ²	0,716600			
R ² Ajustado	0,712300			

Por meio da tabela acima, temos que o modelo considerando agora o esporte agrupado apresentou um ajuste adequado, considerando apenas o intercepto como não-significativo a um nível de 5% de significância, que será mantido por questões de praticidade dos cálculos do modelo. Nota-se ainda que o modelo em questão explica mais de 71% da variabilidade dos dados, apresentando $R^2 = 0,7166$.

4.9.1 Análise das suposições



Com relação à normalidade dos erros, agora percebe-se uma grande quantidade de pontos “saindo” do envelope, e portanto considera-se como um indício de desvio de tal suposição. Abordando a homoscedasticidade, nota-se também uma grande tendência crescente da variância à medida que os valores ajustados aumentam, **não tão evidente** como o modelo anterior, levando a não considerar como um grande indício de desvio dessa suposição. Destacam-se ainda os pontos 56, 160 e 184 como possíveis aberrantes, ou seja, observações que receberam um ajuste ruim. Tratando da não-correlação dos erros, percebe-se também uma maior tendência pelo gráfico dos resíduos studentizados pelos índices, que não aparentam se distribuírem de forma aleatória, indicando assim que há possivelmente evidências de desvio de tal suposição.

Tabela 35: Testes de hipóteses aplicados

Teste	Suposições	P-valor	Decisão
Shapiro-Wilk	Normalidade	0,0003	Rejeita hipótese nula
Breusch-Pagan	Homoscedasticidade	0,0005	Rejeita hipótese nula
Durbin-Watson	Não-Correlação	0,0001	Rejeita hipótese nula

A partir dos resultados obtidos pelos testes, e também pelo que foi percebido nos gráficos, concluímos que esse modelo ajustado não cumpre com nenhuma das suposições.

Tabela 36: Fator de inflação da variância para as covariáveis do modelo

	VIF
BMI	1,336
Sexo	1,334
Esportes	1,278

A partir dos valores de VIF obtidos, não há indícios de multicolinearidade quase exata no modelo 9.

Portanto, concluímos aqui a análise do modelo 9, PBF x BMI, Sexo e Esporte agrupado, visto que o mesmo não cumpre com as suposições necessárias para seu procedimento inferencial.





4.10 Modelo $\log(\text{PBF})$ x BMI, Sexo e Esporte ajustado

Tabela 37: Ajuste do modelo $\log(\text{PBF})$ x BMI, Sexo e Esporte ajustado

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	1,506279	0,148174	10,1656	< 0,0001
BMI	0,062979	0,006413	9,8198	< 0,0001
SexoMasculino	-0,733956	0,036624	-20,0404	< 0,0001
EsportesCategoria 2	-0,164776	0,035851	-4,5962	< 0,0001
R ²	0,755500			
R ² Ajustado	0,751800			

Por meio da tabela acima, temos que o modelo considerando o esporte agrupado e a transformação logarítmica na resposta apresentou um ajuste adequado, considerando todos os coeficientes como significativos a um nível de 5% de significância. Nota-se ainda que o modelo explica mais agora mais de 75% da variabilidade da resposta, apresentando $R^2 = 0,7555$.

4.10.1 Análise das suposições



Com relação à normalidade dos erros, percebe-se uma quantidade considerada de pontos “saindo” do envelope, e portanto considera-se como um indício de desvio de tal suposição. Abordando a homoscedasticidade, nota-se agora uma certa tendência decrescente da variância à medida que os valores ajustados aumentam, ao contrário do que foi apresentado no modelo anterior, sendo considerado como um leve indício de desvio dessa suposição. Destacam-se ainda os pontos 56, 160 e 184 como possíveis aberrantes, ou seja, observações que receberam um ajuste ruim. Tratando da não-correlação dos erros, percebe-se também uma maior tendência crescente pelo gráfico dos resíduos studentizados pelos índices, que não aparentam se distribuírem de forma aleatória, indicando assim que há possivelmente evidências de desvio de tal suposição.

Tabela 38: Testes de hipóteses aplicados

Teste	Suposições	P-valor	Decisão
Shapiro-Wilk	Normalidade	0,0105	Rejeita hipótese nula
Breusch-Pagan	Homoscedasticidade	0,0046	Rejeita hipótese nula
Durbin-Watson	Não-Correlação	<0,001	Rejeita hipótese nula

A partir dos resultados obtidos pelos testes, e também pelo que foi percebido nos gráficos, concluímos que esse modelo ajustado não cumpre com nenhuma das suposições.

Tabela 39: Fator de inflação da variância para as covariáveis do modelo

	VIF
BMI	1,336
Sexo	1,334
Esportes	1,278

A partir dos valores de VIF obtidos, não há indícios de multicolinearidade quase exata no modelo 10.

Portanto, concluímos aqui a análise do modelo 10, $\log(\text{PBF}) \times \text{BMI}$, Sexo e Esporte agrupado, visto que o mesmo não cumpre com as suposições necessárias para seu procedimento inferencial.

4.11 Modelo PBF x LBM, BMI, Sexo e Esporte


Tabela 40: Ajuste do modelo PBF x LBM, BMI, Sexo e Esporte

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	-4,172427	1,853264	-2,2514	0,0255
LBM	-0,274297	0,037062	-7,4011	< 0,0001
BMI	1,548891	0,118704	13,0484	< 0,0001
SexoMasculino	-5,237965	0,725223	-7,2226	< 0,0001
EsporteBBall	5,742291	0,784912	7,3158	< 0,0001
EsporteField	0,678871	0,975464	0,6959	0,4873
EsporteGym	-2,591214	1,405136	-1,8441	0,0667
EsporteNetball	5,909304	0,800219	7,3846	< 0,0001
EsporteRowing	3,758162	0,727684	5,1645	< 0,0001
EsporteSwim	0,805400	0,768504	1,048	0,296
EsporteTennis	1,691412	0,913307	1,852	0,0656
EsporteTSprnt	-1,175863	0,832205	-1,4129	0,1593
EsporteWPolo	4,590221	0,852395	5,3851	< 0,0001
R ²	0,840200			
R ² Ajustado	0,830100			

Por meio da tabela acima, temos que o modelo apresentou um ajuste adequado, considerando 5 coeficientes não significativos a um nível de 5% de significância, nesse caso relacionados

aos esportes Field, Gym, Swim, Tennis e TSpnt, que nesse contexto não apresentam diferença significativa quando troca-se do esporte referência do modelo, nesse caso T400m, para esses outros cinco esportes. Destaca-se ainda que o modelo explica mais de 84% da variabilidade dos dados, apresentando $R^2 = 0,8402$, sendo este o modelo que apresentou maior R^2 .

4.11.1 Análise das suposições



Com relação à normalidade dos erros, percebem-se alguns pontos “saindo” do envelope, mas devido à pequena quantidade, não considera-se um grande desvio à suposição. Abordando a homoscedasticidade, percebe-se agora novamente uma considerável tendência crescente da variância com relação ao aumento dos valores ajustados, apresentando portanto indícios de

desvio dessa suposição. Destaca-se ainda os pontos 56 e 184 como possíveis aberrantes, ou seja, provavelmente essas observações receberam ajustes ruins. Tratando da não-correlação dos erros, não é perceptível nenhum tipo de tendência no gráfico, não apresentando portanto indícios de desvio de tal suposição.

Tabela 41: Testes de hipóteses aplicados

Teste	Suposições	P-valor	Decisão
Shapiro-Wilk	Normalidade	0,1557	Não rejeita hipótese nula
Breusch-Pagan	Homoscedasticidade	0,0359	Rejeita hipótese nula
Durbin-Watson	Não-Correlação	0,7793	Não rejeita hipótese nula

A partir dos resultados obtidos pelos testes, e também pelo que foi percebido nos gráficos, concluímos que esse modelo ajustado não cumpre com a suposição de homoscedasticidade, sendo evidenciado ainda pelo p-valor = 0,0359 do teste Breusch-Pagan, que rejeita a hipótese nula à um nível de significância de 5%.

Tabela 42: Fator de inflação da variância para as covariáveis do modelo

	VIF
LBM	7,245
BMI	3,568
Sexo	4,079
Esporte	3,321

Com relação aos valores de VIF obtidos para as covariáveis do modelo, nota-se o valor de 7,245 para LBM, indicando assim fortes indícios de multicolinearidade no modelo. Dessa forma, descartam-se também possíveis transformações a serem aplicadas, pois essa problemática não seria resolvida a menos da retirada de tal covariável nesse contexto.

Portanto, concluímos aqui a análise do modelo 11, PBF x LBM, BMI, Sexo e Esporte, visto que o mesmo não cumpre com as suposições necessárias para seu procedimento inferencial.

4.12 Modelo PBF x LBM, BMI, Sexo e Esporte agrupado


Tabela 43: Ajuste do modelo PBF x LBM, BMI, Sexo e Esporte ajustado

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	2,198011	2,098478	1,0474	0,2962
LBM	-0,207542	0,040802	-5,0866	< 0,0001
BMI	1,282229	0,123589	10,375	< 0,0001
SexoMasculino	-6,071265	0,85175	-7,128	< 0,0001
EsportesCategoria 2	-3,288839	0,520814	-6,3148	< 0,0001
R ²	0,749500			
R ² Ajustado	0,744400			

Por meio da tabela acima, temos que o modelo considerando a covariável Esporte agrupada apresentou um ajuste adequado, considerando apenas o intercepto como não significativo a

um nível de 5% de significância. Destaca-se ainda que o modelo explica mais de 74% da variabilidade dos dados, apresentando $R^2 = 0,7495$.

4.12.1 Análise das suposições



Com relação à normalidade dos erros, percebe-se agora uma grande quantidade pontos “saindo” do envelope, considerando-se portanto um grande desvio à suposição. Abordando a homoscedasticidade, percebe-se novamente uma considerável tendência crescente da variância com relação ao aumento dos valores ajustados, apresentando portanto indícios de desvio dessa suposição. Destaca-se ainda os pontos 56, 182 e 184 como possíveis aberrantes, ou seja, provavelmente essas observações receberam ajustes ruins. Tratando da não-correlação

dos erros, é perceptível uma certa tendência crescente no gráfico, apresentando portanto consideráveis indícios de desvio de tal suposição.

Tabela 44: Testes de hipóteses aplicados

Teste	Suposições	P-valor	Decisão
Shapiro-Wilk	Normalidade	0,0002	Rejeita hipótese nula
Breusch-Pagan	Homoscedasticidade	0,0071	Rejeita hipótese nula
Durbin-Watson	Não-Correlação	<0,001	Rejeita hipótese nula

A partir dos resultados obtidos pelos testes, e também pelo que foi percebido nos gráficos, concluímos que esse modelo ajustado não cumpre com nenhuma suposição do modelo, apresentando todas as hipóteses nula rejeitadas à um nível de significância de 5%.

Tabela 45: Fator de inflação da variância para as covariáveis do modelo

	VIF
LBM	5,838
BMI	2,572
Sexo	3,741
Esportes	1,398

Com relação aos valores de VIF obtidos para as covariáveis do modelo, nota-se o valor de 5,838 para LBM, indicando assim fortes indícios de multicolinearidade no modelo. Dessa forma, descartam-se também possíveis transformações a serem aplicadas, pois essa problemática não seria resolvida a menos da retirada de tal covariável nesse contexto.

Portanto, concluímos aqui a análise do modelo 12, PBF x LBM, BMI, Sexo e Esporte agrupado, visto que o mesmo não cumpre com as suposições necessárias para seu procedimento inferencial.

5 Conclusão

Por meio dos resultados obtidos para os modelos 3 e 8, acredita-se que o melhor modelo de regressão múltipla ajustado para explicar o percentual de gordura corporal dos atletas do Instituto Australiano de Esporte seja o **Modelo 8: log(PBF) x BMI, Sexo e Esporte**, pois apresentou maior adequabilidade às suposições e não aparenta ser sensível aos pontos atípicos, demonstrando uma certa robustez na estimação dos parâmetros, além de apresentar maior explicabilidade que o modelo 3: log(PBF) x LBM, BMI e Esporte, explicando cerca de 4% a mais de variabilidade da resposta.

Tabela 46: Ajuste do modelo log(PBF) x BMI, Sexo e Esporte

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
Intercepto	1,187544	0,135126	8,7884	< 0,0001
BMI	0,066231	0,006568	10,0846	< 0,0001
SexoMasculino	-0,740867	0,032713	-22,6474	< 0,0001

Coeficientes	Estimativa	Erro Padrão	Estatística T	P-valor
EsporteBBall	0,289453	0,052539	5,5093	< 0,0001
EsporteField	0,071511	0,070937	1,0081	0,3147
EsporteGym	-0,000107	0,101892	-0,001	0,9992
EsporteNetball	0,364961	0,058511	6,2375	< 0,0001
EsporteRowing	0,227320	0,05118	4,4416	< 0,0001
EsporteSwim	0,043052	0,054936	0,7837	0,4342
EsporteTennis	0,175267	0,066943	2,6182	0,0096
EsporteTSprnt	-0,079500	0,06099	-1,3035	0,194
EsporteWPolo	0,398676	0,061715	6,4599	< 0,0001
R ²	0,838100			
R ² Ajustado	0,828800			

Analisando mais especificamente o ajuste do modelo, tem-se a estimativa do intercepto sendo $\beta_0 = 1,187544$, indicando a média do log do percentual de gordura corporal dos atletas quando fixamos todas as demais covariáveis à zero, caso faça sentido. Nesse contexto, a fixação das covariáveis qualitativas à zero implica na média da resposta para uma mulher que pratica o esporte T400m, dado que essas são as categorias de referência, sendo fixada o valor de BMI à zero. Além disso, tem-se cada β_j , $j = 1, \dots, k$, representa a variação na média do logarítmico do Percentual de gordura corporal quando aumenta-se uma unidade na covariável j , dado a fixação dos valores das demais covariáveis. Por exemplo, considerando o coeficiente associado ao sexo masculino, ele representa a variação causada na média da resposta quando passa-se do sexo feminino para o masculino. Ou seja, na prática essa mudança tende a diminuir a média do log do percentual de gordura corporal em 0,74.

Além disso, segue abaixo o intervalo de confiança para os coeficientes:

Tabela 47: Intervalo de confiança para os coeficientes

Coeficientes	Limite Inferior	Limite Superior
Intercepto	0,921	1,454
BMI	0,053	0,079
SexoMasculino	-0,805	-0,676
EsporteBBall	0,186	0,393
EsporteField	-0,068	0,211
EsporteGym	-0,201	0,201
EsporteNetball	0,250	0,480
EsporteRowing	0,126	0,328
EsporteSwim	-0,065	0,151
EsporteTennis	0,043	0,307
EsporteTSprnt	-0,200	0,041
EsporteWPolo	0,277	0,520

Como utilizamos uma transformação na variável resposta para ajustar o modelo, os coeficientes são obtidos considerando a escala transformada. Felizmente, para o caso da transformação logarítmica, é possível facilmente encontrar as estimativas dos coeficientes para a escala da resposta original, apenas aplicando o exponencial nas estimativas do modelo com base na resposta transformada. Um detalhe importante de se salientar, é que para essa “retransformação”, há uma mudança de interpretação dos coeficientes associados à covariáveis, que agora representam a variação percentual aproximada na média do percentual de gordura corporal.

Tabela 48: Estimativa dos coeficientes para a variável original

Coeficientes	Estimativa para original
Intercepto	3,2790180
BMI	1,0684735
SexoMasculino	0,4767004
EsporteBBall	1,3356967
EsporteField	1,0741300
EsporteGym	0,9998930
EsporteNetball	1,4404578
EsporteRowing	1,2552315
EsporteSwim	1,0439922
EsporteTennis	1,1915643
EsporteTSprnt	0,9235780
EsporteWPolo	1,4898508

Ademais, vale destacar que modelo escolhido apresenta $R^2 = 0,8381$, representando que mais de 83% da variabilidade do percentual de gordura corporal está sendo explicada pela modelo, o que é um indicativo de que o modelo consegue explicar bem a variável resposta.

