



**Universidade de Brasília
Departamento de Estatística**

Lista 2 - Análise de Regressão Linear

**Ana Beatriz Silva Martinez
Prof(a). Terezinha Ribeiro**

Relatório apresentado para a disciplina
Análise de Regressão Linear (2024.2)
como parte dos requisitos necessários para
aprovação.

**Brasília
2024**

Sumário

1 Introdução	4
2 Análises descritivas	4
2.1 Transformação de variáveis	8
3 Seleção de variáveis	10
4 Análise de Diagnóstico	11
4.1 Modelo 1: $\log(\text{Fuel}) \times \log(\text{Tax}), \log(\text{Dlic}), \log(\text{Income})$ e $\log(\text{Miles})$	11
4.1.1 Ajuste do modelo	11
4.1.2 Análise de pressupostos	12
4.2 Modelo 2: $\log(\text{Fuel}) \times \log(\text{Dlic}), \log(\text{Income})$ e $\log(\text{Miles})$	13
4.2.1 Ajuste do modelo	13
4.2.2 Análise de pressupostos	14
4.2.3 Análise de alavancagem e pontos de influência	15
4.2.4 Investigação dos pontos influentes	16
4.3 Modelo 3: $\text{Fuel} \times \log(\text{Tax}), \log(\text{Dlic}), \log(\text{Income})$ e $\log(\text{Miles})$	17
4.3.1 Ajuste do modelo	17
4.3.2 Análise de pressupostos	18
4.4 Modelo 4: $\log(\text{Fuel}) \times \text{Tax}, \text{Dlic}, \text{Income}$ e Miles	19
4.4.1 Ajuste do modelo	19
4.4.2 Análise de pressupostos	20
4.5 Modelo 5: $\text{Fuel} \times \text{Tax}, \text{Dlic}, \text{Income}$ e Miles	21
4.5.1 Ajuste do modelo	22
5 Escolha e interpretação do modelo final	23
6 Conclusão (escolha final do modelo)	24

1 Introdução

O presente relatório tem como objetivo a aplicação dos conceitos de Regressão Linear Múltipla, apresentados na disciplina de Análise de Regressão Linear, para modelar e analisar um conjunto de dados real. O foco deste trabalho é a análise do consumo de combustível nos estados norte-americanos, utilizando o banco de dados fuel2001.csv.

Os dados referem-se a informações dos 50 estados norte-americanos mais o Distrito de Columbia, coletados no ano de 2001. A variável resposta de interesse é o consumo de combustível per capita, denotado por Fuel. Para explicar o comportamento desta variável, serão investigadas as seguintes covariáveis: a taxa de imposto sobre a gasolina (Tax), a proporção da população com carteira de motorista (Dlic), a renda per capita (Income) e o total de milhas percorridas em estradas (Miles).

Ao longo deste documento, será conduzida uma análise completa, iniciando com uma análise descritiva para a compreensão inicial das variáveis e suas relações. Em seguida, será abordada a seleção de covariáveis e o ajuste de modelos de regressão candidatos. Estes modelos serão submetidos a uma rigorosa análise de diagnóstico para verificar os pressupostos do modelo linear. Por fim, será selecionado e interpretado o modelo final considerado mais adequado para descrever o consumo de combustível no contexto apresentado.

2 Análises descritivas

Foram gerados histogramas e boxplots, além de um quadro medida-resumo, de cada uma das variáveis do banco de dados para, primeiramente, entender como a variável resposta e suas possíveis covariáveis se comportam.




Figura 1: Histograma da variável Fuel.




Figura 2: Boxplot da variável Fuel.




Figura 3: Histograma da variável Tax.




Figura 4: Boxplot da variável Tax.




Figura 5: Histograma da variável Dlic.




Figura 6: Boxplot da variável Dlic.




Figura 7: Histograma da variável Income.




Figura 8: Boxplot da variável Income.




Figura 9: Histograma da variável Miles.




Figura 10: Boxplot da variável Miles.

Tabela 1: Medidas-resumo das variáveis





Variável	Média	Desvio Padrão	Mínimo	1º Quartil	Mediana	3º Quartil	Máximo
Fuel	0.61	0.09	0.32	0.57	0.63	0.67	0.84
Tax	20.15	4.54	7.50	18.00	20.00	23.25	29.00
Dlic	0.90	0.07	0.70	0.86	0.91	0.94	1.08
Income	28403.90	4451.64	20993.00	25323.00	27871.00	31208.50	40640.00
Miles	77418.59	52983.43	1534.00	36586.00	78914.00	112827.50	300767.00

Analisando a variável resposta consumo de combustível (Fuel), nota-se uma média de 0.61 galões e uma mediana muito próxima, de 0.63, com um desvio padrão de 0.09. A distribuição, observada no histograma e boxplot (Figuras 1 e 2), aparenta ser razoavelmente simétrica, com uma leve assimetria à esquerda e sem a presença de valores atípicos.

Dentre as covariáveis, a taxa sobre o combustível (Tax) e a renda per capita (Income) também apresentam distribuições relativamente simétricas. Em contrapartida, a proporção de motoristas (Dlic), mostra uma assimetria à esquerda, indicando que a maioria dos estados possui uma alta proporção da sua população que é habilitada.

O destaque principal vai para a variável Miles (milhas percorridas), que exhibe uma forte assimetria à direita, como pode ser visto em seu histograma. Isso indica que, apesar de a maioria dos estados terem um número de milhas em um certo patamar, alguns poucos estados possuem um valor muito superior, o que também é evidenciado pelo alto valor do seu desvio padrão em comparação com a média.

Analisa-se também de o comportamento da variável resposta (Fuel) com cada uma de suas possíveis covariáveis.



A partir dos gráficos, a relação mais evidente é entre o consumo de combustível (Fuel) e a taxa de imposto (Tax). Observa-se uma clara tendência linear negativa, sugerindo que estados com maiores taxas de imposto sobre o combustível tendem a apresentar um menor consumo per capita.

A variável Dlic, que representa a proporção de motoristas, aparenta ter uma relação linear positiva com Fuel, indicando que quanto maior a proporção de motoristas na população, maior tende a ser o consumo de combustível. No entanto, a dispersão dos pontos neste gráfico sugere que essa relação pode ser menos intensa que a observada para a variável Tax.

Por fim, as covariáveis Income (renda per capita) e Miles (milhas de estrada) não apresentam uma relação linear clara com a variável resposta. Em ambos os gráficos, os pontos encontram-se dispersos e sem uma tendência bem definida, indicando que, a princípio, estas variáveis podem não ser fortes preditoras lineares para o consumo de combustível.

O coeficiente de correlação de Pearson foi calculado para entender melhor o grau de correlação entre a variável resposta e suas possíveis covariáveis, o que é evidenciado no gráfico a seguir:




Figura 11: Matriz de correlação

A análise da matriz confirma e reforça as impressões visuais. A variável Tax (taxa de imposto) demonstra a correlação linear mais forte e promissora com a resposta Fuel, apresentando um coeficiente de -0.63. A variável Dlic (proporção de motoristas) também mostra uma correlação positiva moderada de 0.40, o que é consistente com a intuição teórica. Em contraste, Income e Miles apresentam correlações lineares muito fracas com o consumo, de 0.17 e -0.11, respectivamente, sugerindo que, em suas escalas originais, possuem baixo poder preditivo.

No entanto, o achado mais crítico desta análise é a forte correlação negativa entre as próprias variáveis preditoras, especificamente entre Tax e Income, com um coeficiente de -0.76. Esta é uma forte indicação de potencial multicolinearidade, um problema que pode desestabilizar o modelo e afetar a confiabilidade dos coeficientes.

Estas observações são fundamentais e guiarão a próxima etapa do trabalho. A forte assimetria da variável Miles e as relações não-lineares sugerem a necessidade de explorar transformações de variáveis para aprimorar a estrutura do modelo.

2.1 Transformação de variáveis

Com base nos achados da análise descritiva, notadamente a forte assimetria da variável Miles e a fraca relação linear aparente entre algumas covariáveis e a resposta, procedeu-se com a exploração de transformações. O objetivo desta etapa é avaliar se a aplicação da transformação logarítmica pode linearizar as relações e, consequentemente, produzir modelos de regressão mais adequados.

A Figura X apresenta uma comparação visual do efeito da transformação na

relação entre o consumo (Fuel) e as milhas percorridas (Miles).




Figura 12: Gráficos de correlação Fuel Vs Miles e suas respectivas transformações

Analisando a figura, a relação original entre Fuel e Miles (Gráfico 1) é fraca e dispersa. Ao transformar apenas a variável Miles para a escala de log (Gráfico 2), a relação se torna visualmente mais forte. A transformação isolada da resposta Fuel (Gráfico 3) apresenta uma melhora mais modesta. No entanto, a melhora mais significativa ocorre no Gráfico 4, onde ambas as variáveis estão na escala logarítmica ($\log(\text{Fuel})$ vs. $\log(\text{Miles})$), exibindo a tendência linear mais clara e definida entre as quatro configurações.

Esta impressão visual é confirmada e quantificada pelos coeficientes de correlação de Pearson. A correlação original entre Fuel e Miles era de apenas 0.21. Após a transformação Log-Log, a correlação mais do que dobrou, atingindo um valor de 0.47.

Esta forte evidência visual e numérica justifica a inclusão de variáveis transformadas na próxima etapa de ajuste e seleção de modelos, pois sugere que as formas funcionais logarítmicas são mais promissoras para capturar adequadamente as relações presentes nos dados.

3 Seleção de variáveis

Existem diversos procedimentos e critérios para a seleção de um subconjunto de covariáveis para serem incorporadas no modelo. O objetivo consiste em escolher o modelo mais parcimonioso, isto é, selecionar as covariáveis que conduzam a um modelo de regressão ajustado com boa explicação e o menor número de parâmetros possível.

Para tal, foram utilizados três métodos de seleção de covariáveis: o método Backward (passo atrás), iniciando com o modelo contendo todas as covariáveis; o método Forward (passo a frente), iniciando com o modelo contendo apenas o intercepto; e o método Stepwise (passo a passo). Para todos os procedimentos, foi considerado o Critério de Informação de Akaike (AIC) como medida de avaliação dos modelos.

Este processo foi aplicado às quatro "famílias" de modelos exploradas na seção anterior (Level-Level, Log-Level, Level-Log e Log-Log). A conclusão foi consistente entre os métodos: para cada família, o modelo que apresentou o menor valor de AIC foi o modelo completo, contendo todas as quatro covariáveis.

Apesar de os métodos automáticos sugerirem a manutenção de todas as variáveis, para garantir uma análise de diagnóstico abrangente, foram selecionados cinco modelos candidatos. Esta lista inclui os modelos com melhor performance geral e variações mais simples, que serão avaliados na próxima seção. A Tabela X apresenta os modelos selecionados.

Tabela 2: Modelos candidatos selecionados para a Análise de Diagnóstico.

Modelo	Resposta	Covariáveis
1	log(Fuel)	log(Tax), log(Dlic), log(Income), log(Miles)
2	log(Fuel)	log(Dlic), log(Income), log(Miles)
3	Fuel	log(Tax), log(Dlic), log(Income), log(Miles)
4	log(Fuel)	Tax, Dlic, Income, Miles
5	Fuel	Tax, Dlic, Income, Miles

4 Análise de Diagnóstico

4.1 Modelo 1: $\log(\text{Fuel})$ X $\log(\text{Tax})$, $\log(\text{Dlic})$, $\log(\text{Income})$ e $\log(\text{Miles})$

4.1.1 Ajuste do modelo

Tabela 3: Resultados do ajuste do Modelo 1 (Log-Log Completo).


Coeficiente	Estimativa	Erro Padrão	Estatística t	p-valor
Intercepto	2.31538	1.22095	1.896	0.0642
$\log(\text{Tax})$	-0.08599	0.05967	-1.441	0.1563
$\log(\text{Dlic})$	0.87304	0.19994	4.367	< 0.001
$\log(\text{Income})$	-0.30186	0.11124	-2.714	0.0093
$\log(\text{Miles})$	0.05700	0.01621	3.516	0.0010
R^2 : 0.5572				
R^2 Ajustado: 0.5187				

Para iniciar a análise de diagnóstico, o Modelo 1 (Log-Log Completo) foi formalmente ajustado. A Tabela 3 mostra os resultados.

A primeira coisa que chama a atenção é o R^2 Ajustado de 0.5187. Isso é um ótimo sinal, pois indica que o modelo consegue explicar aproximadamente 52% da variabilidade na resposta $\log(\text{Fuel})$. O p-valor geral do modelo (teste F) também foi super baixo, confirmando que o modelo como um todo é estatisticamente significativo.

Olhando os coeficientes, as variáveis $\log(\text{Dlic})$, $\log(\text{Income})$ e $\log(\text{Miles})$ se mostraram muito significativas (p-valores bem pequenos). A surpresa foi a $\log(\text{Tax})$, que, neste modelo, não foi estatisticamente significativa ($p = 0.156$), sugerindo que sua contribuição pode ser redundante na presença das outras variáveis.

4.1.2 Análise de pressupostos



A análise visual dos gráficos de diagnóstico para o Modelo 1 é, a princípio, bastante promissora. Os gráficos de envelope (Normal e T) sugerem que a suposição de normalidade dos resíduos é atendida, com os pontos seguindo bem a linha de referência. Da mesma forma, o gráfico de Resíduos vs. Valores Ajustados não aparenta ter padrões evidentes, como um formato de cone, indicando que a homocedasticidade (variância constante) também parece ser satisfeita. Por fim, o gráfico de Resíduos vs. Índices não mostra tendências claras, apoiando a suposição de independência.

Para confirmar essas impressões visuais de forma estatística, foram realizados os testes formais de Shapiro-Wilk (para normalidade), Breusch-Pagan (para homocedasticidade) e Durbin-Watson (para independência). Os resultados são apresentados na Tabela 4.

Tabela 4: Resultados dos testes de diagnóstico para o Modelo 1.

Suposição	Teste	p-valor	Decisão ($\alpha = 5\%$)
Normalidade	Shapiro-Wilk	0.1004	Não Rejeita H_0
Homocedasticidade	Breusch-Pagan	0.0445	Rejeita H_0
Independência	Durbin-Watson	0.3680	Não Rejeita H_0

Os resultados dos testes confirmam nossas suspeitas visuais para a normalidade ($p = 0.10$) e independência ($p = 0.37$), já que não rejeitamos a hipótese nula em ambos os casos.

No entanto, o resultado mais crítico veio do teste de Breusch-Pagan. Com um p-valor de 0.044, ele rejeita a hipótese nula de homocedasticidade. Este resultado, apesar de a inspeção visual não ser tão alarmante, é uma forte evidência estatística de que o Modelo 1 viola um dos pressupostos fundamentais da regressão linear.

Dada esta falha no pressuposto de variância constante, o Modelo 1 é considerado inadequado e será descartado. A análise prosseguirá com o próximo candidato.

4.2 Modelo 2: $\log(\text{Fuel})$ X $\log(\text{Dlic})$, $\log(\text{Income})$ e $\log(\text{Miles})$

4.2.1 Ajuste do modelo

Tabela 5: Resultados do ajuste do Modelo 2 (Log-Log Simplificado).

Coeficiente	Estimativa	Erro Padrão	Estatística t	p-valor
Intercepto	1.94610	1.20736	1.612	0.1137
$\log(\text{Dlic})$	0.90997	0.20054	4.538	< 0.001
$\log(\text{Income})$	-0.29092	0.11224	-2.592	0.0127
$\log(\text{Miles})$	0.05751	0.01639	3.508	0.0010
R^2 : 0.5372				
R^2 Ajustado: 0.5077				

Dando sequência, a Tabela 5 mostra os resultados do Modelo 2, uma versão simplificada do nosso candidato anterior, agora sem a variável $\log(\text{Tax})$.


A primeira coisa a se notar é que, mesmo com uma variável a menos, o modelo continua bem forte. O R^2 Ajustado ficou em 0.5077, ou seja, ele ainda explica quase 51% da variabilidade do $\log(\text{Fuel})$. A queda em relação ao Modelo 1 (que tinha 52%) foi mínima, o que é um ótimo sinal!

O mais interessante é que agora todas as variáveis no modelo ($\log(\text{Dlic})$, $\log(\text{Income})$ e $\log(\text{Miles})$) são estatisticamente muito significativas. Ao remover a $\log(\text{Tax})$, que não era significativa e tinha correlação com $\log(\text{Income})$, o modelo ficou mais "limpo" e parcimonioso.

Este modelo parece ser um candidato muito forte, já que é mais simples que o

Modelo 1 e manteve quase todo o seu poder explicativo.

4.2.2 Análise de pressupostos



A análise visual dos gráficos é **extremamente positiva**. No painel de normalidade ("Envelope Dist. Normal"), os resíduos se distribuem perfeitamente dentro das bandas de confiança, indicando forte aderência à distribuição normal. O gráfico de Resíduos vs. Valores Ajustados mostra uma nuvem de pontos aleatória e horizontal, sem padrões de funil ou cone, o que é uma forte evidência visual a favor da homocedasticidade (variância constante). Da mesma forma, o gráfico de Resíduos vs. Índices não apresenta nenhuma tendência, sugerindo que a suposição de independência dos erros é válida.

Para confirmar numericamente estas impressões visuais, foram realizados os testes formais de diagnóstico, cujos resultados estão na Tabela 6.

Tabela 6: Resultados dos testes de diagnóstico para o Modelo 2.

Suposição	Teste	p-valor	Decisão ($\alpha = 5\%$)
Normalidade	Shapiro-Wilk	0.8846	Não Rejeita H_0
Homocedasticidade	Breusch-Pagan	0.2509	Não Rejeita H_0
Independência	Durbin-Watson	0.6000	Não Rejeita H_0


Os resultados dos testes corroboram fortemente a análise visual. Com p-valores altos para os testes de Shapiro-Wilk ($p=0.88$) e Durbin-Watson ($p=0.60$), as suposições de normalidade e independência dos erros são satisfeitas.

O resultado mais crucial, no entanto, é o do teste de Breusch-Pagan. Com um p-valor de 0.25, o teste não rejeita a hipótese de homocedasticidade. Isso significa que, ao contrário do Modelo 1, o Modelo 2 passa em todos os testes de pressupostos fundamentais. A simplificação do modelo, ao remover a variável $\log(\text{Tax})$ que era pouco significativa e correlacionada com $\log(\text{Income})$, não só tornou o modelo mais parcimonioso, como também resolveu o problema de heterocedasticidade.

Com base na análise de diagnóstico, o Modelo 2 ($\log(\text{Fuel}) = \log(\text{Dlic}) + \log(\text{Income}) + \log(\text{Miles})$) se mostra robusto, válido e um forte candidato a ser o modelo final.


4.2.3 Análise de alavancagem e pontos de influência

Após a verificação dos pressupostos do modelo, a análise de diagnóstico prossegue com a investigação de observações atípicas, que são classificadas em pontos de alavancagem (leverage) e pontos influentes. Pontos de alavancagem são observações com valores de covariáveis incomuns, que têm o potencial de puxar a reta de regressão em sua direção. Pontos influentes são aqueles que, se removidos, causam mudanças significativas nas estimativas dos coeficientes do modelo. A identificação e análise desses pontos é crucial para garantir a robustez e a confiabilidade do modelo final.



A Figura apresenta os valores de alavancagem (hat values) para cada observação. Pontos com valores acima do critério de referência ($2p/n$) são considerados pontos de

alavancagem e merecem investigação. Para este modelo, foram identificados os seguintes estados como pontos de alavancagem: CT, DC, HI e NY.



Em seguida, a influência de cada observação sobre os resultados do modelo foi avaliada através das métricas DFFITS e Distância de Cook, apresentadas na Figura. Ambas as métricas buscam identificar pontos que, se removidos, alterariam significativamente as estimativas dos coeficientes.

As duas análises apontaram para um conjunto consistente de observações como potencialmente influentes. As observações identificadas foram: AK, DE, DC, HI, MN, NY e WY.

4.2.4 Investigação dos pontos influentes

Tabela 7: Comparação do Modelo 2 com e sem os pontos atípicos.

Coeficiente	Estimativa Original	Estimativa (Refit)
Intercepto	1.9461	1.4705
log(Dlic)	0.9100	0.5080
log(Income)	-0.2909	-0.2197
log(Miles)	0.0575	0.0316
R² Ajustado	0.5077	0.2496

A partir da análise de diagnóstico, foram identificadas as observações AK, CT, DE, DC, HI, MN, NY e WY como possíveis pontos de alavanca e/ou influência. Para investigar o impacto real desses pontos sobre as estimativas, o Modelo 2 foi reajustado utilizando um novo conjunto de dados sem essas observações. A Tabela 7 compara os coeficientes e o R² Ajustado do modelo original e do modelo reajustado.

A análise da tabela revela um resultado crítico: o modelo é altamente sensível à remoção desses pontos. O R^2 Ajustado sofreu uma queda drástica, caindo de 0.5077 para 0.2496, o que significa que o poder explicativo do modelo foi praticamente cortado pela metade.

Além disso, as estimativas dos coeficientes sofreram alterações substanciais, com reduções de mais de 40% nos efeitos de $\log(\text{Dlic})$ e $\log(\text{Miles})$. Mais importante ainda, a variável $\log(\text{Miles})$, que era estatisticamente significativa no modelo original, tornou-se não significativa ($p = 0.0821$) após a remoção dos pontos atípicos.

A forte dependência dos resultados em um pequeno conjunto de observações indica que o Modelo 2, apesar de ter passado nos testes de pressupostos, não é um modelo robusto. Seu bom desempenho aparente era, em grande parte, uma consequência desses pontos influentes. Portanto, o Modelo 2 também é descartado.

4.3 Modelo 3: Fuel X $\log(\text{Tax})$, $\log(\text{Dlic})$, $\log(\text{Income})$ e $\log(\text{Miles})$

4.3.1 Ajuste do modelo

Tabela 8: Resultados do ajuste do Modelo 3 (Level-Log Completo).

Coeficiente	Estimativa	Erro Padrão	Estatística t	p-valor
Intercepto	2.32668	0.70223	3.313	0.0018
$\log(\text{Tax})$	-0.06213	0.03432	-1.810	0.0768
$\log(\text{Dlic})$	0.42594	0.11499	3.704	0.001
$\log(\text{Income})$	-0.17377	0.06398	-2.716	0.0093
$\log(\text{Miles})$	0.02708	0.00933	2.904	0.0056
$R^2 : 0.5049$				
$R^2 \text{ Ajustado: } 0.4619$				


Seguindo a análise, agora é a vez do Modelo 3 (Level-Log). A Tabela 8 mostra o que a gente encontrou.

O R^2 Ajustado ficou em 0.4619, o que quer dizer que ele explica cerca de 46% da variabilidade do Fuel. É um resultado bom, bem melhor que o nosso modelo base, mas não tão forte quanto os modelos que usaram $\log(\text{Fuel})$ na resposta.

Olhando os coeficientes, a história é bem parecida com a que já vimos: $\log(\text{Dlic})$, $\log(\text{Income})$ e $\log(\text{Miles})$ são super significativos. A $\log(\text{Tax})$ continua naquela zona cinzenta ($p = 0.076$), sendo marginalmente significativa.

No geral, é um bom modelo, mas até agora, a família Log-Log (Modelos 1 e 2) parece ter uma vantagem em poder de explicação.

4.3.2 Análise de pressupostos



A análise visual dos gráficos de diagnóstico para o Modelo 3, apresentada na Figura X, mostra um cenário misto. Os gráficos de normalidade ("Envelope Dist. Normal") e de independência ("Resíduos vs. Índices") não apresentam desvios preocupantes, sugerindo que esses pressupostos podem ser satisfeitos.

O ponto de atenção, no entanto, está no gráfico de Resíduos vs. Valores Ajustados. Nele, é possível notar um padrão em que a dispersão dos resíduos tende a aumentar conforme os valores ajustados crescem, formando um leve "cone". Isso é um indício visual de um possível problema de heterocedasticidade (variância não constante).

Para uma conclusão definitiva, foram realizados os testes formais de diagnóstico. Os resultados estão na Tabela 9.

Tabela 9: Resultados dos testes de diagnóstico para o Modelo 3.

Suposição	Teste	p-valor	Decisão ($\alpha = 5\%$)
Normalidade	Shapiro-Wilk	0.0833	Não Rejeita H_0
Homocedasticidade	Breusch-Pagan	0.0407	Rejeita H_0
Independência	Durbin-Watson	0.3580	Não Rejeita H_0

Os testes confirmam que os pressupostos de normalidade ($p = 0.083$) e independência ($p = 0.358$) são satisfeitos.

Contudo, o resultado decisivo, assim como no Modelo 1, vem do teste de Breusch-Pagan. Com um p-valor de 0.040, o teste rejeita a hipótese nula de homocedasticidade, confirmando a suspeita levantada pelo gráfico. A violação deste pressuposto fundamental compromete a validade das inferências do modelo.

Por falhar no teste de variância constante, o Modelo 3 também é considerado inadequado e será descartado.

4.4 Modelo 4: $\log(\text{Fuel})$ X Tax, Dlic, Income e Miles

4.4.1 Ajuste do modelo

Tabela 10: Resultados do ajuste do Modelo 4 (Log-Level Completo).

Coeficiente	Estimativa	Erro Padrão	Estatística t	p-valor
Intercepto	-1.066e+00	2.964e-01	-3.596	0.001
Tax	-5.711e-03	3.769e-03	-1.515	0.1365
Dlic	1.088e+00	2.456e-01	4.430	0.001
Income	-1.293e-05	3.944e-06	-3.279	0.0020
Miles	8.285e-07	3.349e-07	2.474	0.0171
R^2 : 0.5038				
R^2 Ajustado: 0.4606				


Analizando agora o Modelo 4 (Log-Level), a Tabela 10 resume seus resultados. O R^2 Ajustado foi de 0.4606, mostrando que o modelo explica 46% da variabilidade do $\log(\text{Fuel})$. Esse resultado é bem similar ao do Modelo 3 (Level-Log), mas inferior ao do Modelo 2 (Log-Log Simplificado) que atingiu quase 51%.

Assim como nos outros modelos com $\log(\text{Fuel})$ na resposta, a variável Tax não

se mostrou estatisticamente significativa ($p = 0.136$), enquanto Dlic, Income e Miles continuam sendo preditores importantes.

Até o momento, o Modelo 2 (Log-Log Simplificado) continua sendo nosso candidato mais forte, tanto em poder explicativo quanto em simplicidade.

4.4.2 Análise de pressupostos



A análise visual dos gráficos revela problemas significativos. No gráfico de normalidade "Envelope Dist. T", é possível observar diversos pontos, especialmente nas caudas da distribuição, que escapam das bandas de confiança, fornecendo uma forte evidência visual contra a suposição de normalidade dos resíduos.

Ainda mais problemático é o gráfico de "Resíduos vs. Valores Ajustados". Ele exibe um claro padrão de cone, onde a dispersão (variância) dos resíduos aumenta conforme os valores ajustados crescem. Este é um sinal clássico de heterocedasticidade, uma violação do pressuposto de variância constante. Os demais gráficos não indicam problemas de independência ou de pontos excessivamente influentes.

Para confirmar numericamente estas impressões visuais, foram realizados os testes formais de diagnóstico, cujos resultados estão na Tabela .

Tabela 11: Resultados dos testes de diagnóstico para o Modelo 4.

Suposição	Teste	p-valor	Decisão ($\alpha = 5\%$)
Normalidade	Shapiro-Wilk	0.0152	Rejeita H_0
Homocedasticidade	Breusch-Pagan	0.0011	Rejeita H_0
Independência	Durbin-Watson	0.2800	Não Rejeita H_0

Os testes estatísticos confirmam de forma decisiva os problemas graves identificados nos gráficos. Com p-valores de 0.0152 para o teste de Shapiro-Wilk e 0.0011 para o teste de Breusch-Pagan, as hipóteses nulas de normalidade e de homocedasticidade são fortemente rejeitadas.

Conclusão sobre o Modelo 4: A violação de dois dos três pressupostos fundamentais da regressão linear (normalidade e variância constante) invalida o uso deste modelo para fins de inferência estatística. Portanto, o Modelo 4 é descartado.


4.5 Modelo 5: Fuel X Tax, Dlic, Income e Miles

Tabela 12: Resultados do ajuste do Modelo 5 (Base Completo).

Coefficiente	Estimativa	Erro Padrão	Estatística t	p-valor
Intercepto	3.840e-01	1.658e-01	2.316	0.0250
Tax	-4.115e-03	2.107e-03	-1.952	0.0570
Dlic	5.353e-01	1.373e-01	3.898	0.001
Income	-7.137e-06	2.205e-06	-3.236	0.0022
Miles	4.016e-07	1.873e-07	2.144	0.0373
R^2 : 0.4755				
R^2 Ajustado: 0.4299				

O último candidato avaliado é o Modelo 5, que representa o modelo base, sem nenhuma transformação nas variáveis. A Tabela 12 resume seu ajuste, que apresentou o menor poder explicativo entre os finalistas, com um R^2 Ajustado de 0.4299.

4.5.1 Ajuste do modelo



O gráfico de normalidade ("Envelope Dist. T") já mostra alguns pontos escapando das bandas de confiança nas caudas da distribuição, levantando uma primeira suspeita sobre a normalidade. O problema mais evidente, no entanto, está no gráfico de Resíduos vs. Valores Ajustados, que exhibe um forte padrão de cone. Isso indica que a variância dos resíduos não é constante, um sinal claro de heterocedasticidade.

Para confirmar numericamente estas impressões visuais, foram realizados os testes formais de diagnóstico, cujos resultados estão na Tabela 13.

Tabela 13: Resultados dos testes de diagnóstico para o Modelo 5.

Suposição	Teste	p-valor	Decisão ($\alpha = 5\%$)
Normalidade	Shapiro-Wilk	0.0418	Rejeita H_0
Homocedasticidade	Breusch-Pagan	0.0049	Rejeita H_0
Independência	Durbin-Watson	0.2560	Não Rejeita H_0

Os testes confirmam de forma decisiva os problemas graves identificados nos gráficos. Com p-valores de 0.041 para o teste de Shapiro-Wilk e 0.005 para o teste de Breusch-Pagan, as hipóteses nulas de normalidade e homocedasticidade são rejeitadas.



Por apresentar o menor R^2 Ajustado entre os candidatos e falhar em dois pressupostos fundamentais, o Modelo 5 é conclusivamente descartado.

5 Escolha e interpretação do modelo final

Após uma rigorosa etapa de análise de diagnóstico, que avaliou cinco modelos candidatos quanto à adequação aos pressupostos da regressão linear, chegou-se a uma conclusão clara. Os modelos 1, 3, 4 e 5 foram descartados por apresentarem violações significativas em pressupostos fundamentais, como normalidade e homocedasticidade.

O único candidato que satisfaz todos os testes de pressupostos foi o Modelo 2 (Log-Log Simplificado). No entanto, a análise de influência revelou que este modelo era sensível a um pequeno conjunto de observações atípicas, o que poderia comprometer a confiabilidade de suas inferências.

Para contornar este desafio e garantir a máxima robustez das conclusões, optou-se por manter a estrutura do Modelo 2, mas recalcular seus coeficientes utilizando erros padrão robustos à heterocedasticidade (Eicker-Huber-White). Esta abordagem avançada ajusta os testes de hipótese para serem válidos mesmo na presença de pequenas imperfeições nos dados, resultando em inferências mais confiáveis. A Tabela 14 apresenta os resultados finais do modelo escolhido.

Tabela 14: Resultados finais do Modelo 2 ajustado com erros padrão robustos.

Coefficiente	Estimativa	Erro Padrão Robusto	Estatística t	p-valor
Intercepto	1.9461	1.0963	1.775	0.0823
log(Dlic)	0.9100	0.2613	3.483	0.0011
log(Income)	-0.2909	0.0979	-2.971	0.0047
log(Miles)	0.0575	0.0190	3.023	0.0040
<i>R^2 Múltiplo: 0.5372, R^2 Ajustado: 0.5077</i>				

Interpretação dos Coeficientes

Com base nos resultados robustos, a um nível de significância de 5%, todas as covariáveis no modelo final são estatisticamente significativas para explicar o consumo de combustível per capita. A interpretação dos coeficientes, por se tratar de um modelo Log-Log, é dada em termos de elasticidades (variações percentuais):

log(Dlic): Para cada aumento de 1% na proporção de motoristas (Dlic), o consumo de combustível per capita (Fuel) tende a aumentar, em média, 0.91%, mantendo as outras variáveis constantes.

$\log(\text{Income})$: Para cada aumento de 1% na renda per capita (Income), o consumo de combustível tende a diminuir, em média, 0.29%, mantendo as outras variáveis constantes. O sinal negativo, embora contraintuitivo, foi consistente em todas as modelagens e pode refletir fatores não medidos, como a maior eficiência de veículos em estados com maior renda.

$\log(\text{Miles})$: Para cada aumento de 1% no total de milhas de estradas (Miles), o consumo de combustível tende a aumentar, em média, 0.057

6 Conclusão (escolha final do modelo)

Este trabalho teve como objetivo desenvolver um modelo de regressão linear múltipla para explicar o consumo de combustível per capita (Fuel) nos estados norte-americanos. A partir de uma análise descritiva detalhada, seguida por uma rigorosa etapa de exploração de transformações e seleção de variáveis, chegou-se a um modelo final robusto e com bom poder explicativo.

O modelo escolhido, $\log(\text{Fuel}) = \log(\text{Dlic}) + \log(\text{Income}) + \log(\text{Miles})$, demonstrou ser o único, dentre os candidatos, a satisfazer os pressupostos do modelo linear, explicando aproximadamente 51% da variabilidade do logaritmo do consumo de combustível. A utilização de erros padrão robustos garantiu a validade das inferências.

Conclui-se que a proporção de motoristas (Dlic) e o total de milhas (Miles) são os principais fatores que impactam positivamente o consumo, enquanto a renda per capita (Income) apresentou um efeito negativo significativo. O modelo final obtido representa uma ferramenta válida e parcimoniosa para entender os determinantes do consumo de combustível no contexto analisado.