



**Universidade de Brasília
Departamento de Estatística**

Lista Prática 2

Iza Débora Almeida Santos

Relatório apresentado para a disciplina
ANÁLISE DE REGRESSÃO LINEAR -
EST0038 como parte dos requisitos ne-
cessários para aprovação.

**Brasília
2025**

Sumário

1 Introdução	5
2 Análise descritiva	5
2.1 Transformações de variáveis	10
3 Seleção de modelos	12
4 Análise diagnóstica	13
4.1 Fuel x Dlic,Income,Miles e Tax	13
4.1.1 Suposições e análise diagnostica	14
4.1.2 Alavancagem e pontos de influencia	15
4.1.3 Investigação de pontos influentes	17
4.2 Fuel x Dlic,Income e Miles	18
4.2.1 Suposições e análise diagnostica	19
4.3 $\log(\text{Fuel}) \times \log(\text{Dlic}), \text{Income}, \text{Miles}$ e Tax.	21
4.3.1 Suposições e análise diagnostica	21
4.3.2 Alavancagem e pontos de influencia	23
4.3.3 Investigação dos pontos influentes	25
4.4 $\log(\text{Fuel})$ Dlic,Income,Miles e Tax	26
4.4.1 Suposições e análise diagnostica	27
4.4.2 Alavancagem e pontos de influencia	28
4.4.3 Investigação de pontos influentes	30
4.5 $\log(\text{Fuel})$ Dlic,Income, $\log(\text{Miles})$ Tax.	31
4.5.1 Suposições e análise diagnostica	32
4.5.2 Alavancagem e pontos de influencia	33
4.5.3 Investigação de pontos influentes	35
4.6 $\log(\text{Fuel}) \log(\text{Dlic})$ Income e Miles.	36
4.6.1 Suposições e análise diagnostica	37
4.6.2 Alavancagem e pontos de influencia	38
4.6.3 Investigação de pontos influentes	41
4.7 Interações de Primeira Ordem	41

5 Conclusão	42
------------------------------	-----------

1 Introdução

O presente relatório tem como objetivo realizar uma análise de regressão linear múltipla (MRLM) utilizando dados referentes aos 50 estados norte-americanos e o Distrito de Columbia no ano de 2001. O conjunto de dados disponibilizado inclui informações como o número de motoristas licenciados, o total de gasolina vendida, a renda per capita, o total de milhas em rodovias federais, a população com idade igual ou superior a 16 anos e a taxa de gasolina.

Para tornar as comparações entre os estados mais adequadas, foram construídas duas variáveis derivadas: Fuel, definida como o total de gasolina vendida dividido pela população com 16 anos ou mais, e Dlic, que representa a proporção de motoristas licenciados em relação à mesma população. A variável Fuel será tratada como resposta ao longo do relatório, enquanto Dlic, juntamente com Income, Miles e Tax, será considerada como covariável explicativa.

O principal objetivo da análise é modelar a média de gasolina vendida por estado com base nas demais variáveis disponíveis, de modo a compreender os fatores associados ao consumo de combustível. Para isso, são exploradas transformações logarítmicas, quando necessárias, bem como ajustes de modelos de regressão múltipla, seleção de covariáveis e inclusão de termos de interação de primeira ordem.

2 Análise descritiva

Com o objetivo de compreender melhor as variáveis do conjunto de dados, foram elaborados gráficos boxplot para cada uma delas acrescido de um quadro de medidas resumo, descrevendo assim a disposição geral dos valores observados. Todos os indicadores analisados são variáveis quantitativas e discretas. A análise dos boxplots permite identificar possíveis valores discrepantes (outliers), bem como observar a tendência central e a dispersão de cada variável, contribuindo para uma melhor interpretação dos dados antes do ajuste do modelo de regressão.






Figura 1: Gráfico box-plot da variável Fuel(Média de gasolina vendida) - Dados fuel2001




(a) Dlic (Motoristas licenciados levando em conta a população)




(b) Income (Renda per capita em 2000)

Figura 2: Gráficos box-plot das covariáveis Dlic e Income - Dados fuel2001



(a) Miles (Total de milhas emestradas federais)



(b) Tax (Taxa de gasolina)

Figura 3: Gráficos box-plot das covariáveis Miles e Tax - Dados fuel2001

Tabela 1: Tabela de medidas resumo das variáveis - Dados fuel2001

Medida	Fuel	Dlic	Income	Miles	Tax
Média	0,61	0,90	28404,00	77419,00	20,15
Desvio-Padrão	0,09	0,07	4.451,64	52.983,43	4,54
Mínimo	0,32	0,70	20993,00	1534,00	7,50
1° quartil	0,57	0,86	25323,00	36586,00	18,00
Mediana	0,62	0,91	27871,00	78914,00	20,00
3° quartil	0,66	0,94	31209,00	112828,00	23,25
Máximo	0,84	1,07	40640	300767	29,00
Coefficiente de variação	0,14	0,08	0,16	0,69	0,22

Pelos gráfico das Figura 1, observa-se que o boxplot da variável *Fuel* apresenta uma caixa relativamente pequena, indicando que os valores estão concentrados próximos à média, com baixa dispersão. O coeficiente de variação, de apenas 14%, reforça essa interpretação. A média, de 0,61, é bastante próxima da mediana, de 0,62, o que evidencia a ausência de assimetria significativa e confirma a concentração dos dados em torno da tendência central. O tamanho interquartil (IQR), igual a 0,09, também indica baixa variabilidade dentro do intervalo interquartil. Além disso, identificam-se quatro valores atípicos (outliers), sendo um localizado na cauda superior e três na cauda inferior, sugerindo pequenas variações extremas em relação ao padrão geral da variável.

A variável *Dlic*, apresentada no boxplot da Figura 2, mostra três pontos discrepantes (outliers), sendo um localizado acima da cauda superior e dois abaixo da cauda inferior. Observa-se que a média (0,90) é muito próxima da mediana (0,91), o que indica baixa dispersão e sugere ausência de assimetria significativa. Além disso, a posição central da mediana dentro da caixa reforça essa percepção de simetria. O coeficiente de variação, de apenas 8%, confirma que os dados de *Dlic* apresentam uma variabilidade relativamente baixa em relação à média.

Já a variável *Income*, representada no boxplot da Figura 2, apresenta uma caixa relativamente maior, indicando maior dispersão dos dados em comparação com as demais variáveis. O intervalo interquartil (IQR) é de 5.886, o que evidencia essa maior variabilidade dentro do grupo central de valores. A média, de 28.404, não está tão próxima da mediana, de 27.871, mas a diferença entre elas também não é expressiva o suficiente para indicar forte assimetria. Esse comportamento se confirma pelo coeficiente de variação de 16%, sugerindo uma dispersão moderada. Além disso, observa-se apenas um ponto discrepante (outlier) na cauda superior, próximo de 40.000, indicando um valor extremo isolado em relação ao padrão geral da variável.

A variável *Miles*, apresentada no boxplot da Figura 3, mostra que a média

(77.419) é muito próxima da mediana (78.914), indicando uma distribuição aproximadamente simétrica. O intervalo interquartil (IQR) é de 76.242, o que revela uma alta dispersão dos valores observados. Essa interpretação é reforçada pelo coeficiente de variação, que atinge 69%, caracterizando uma variabilidade significativa em relação à média. Além disso, identifica-se um ponto discrepante (outlier) na cauda superior, que possivelmente contribui para essa maior variação observada.

Por fim, a variável *Tax*, apresentada no boxplot da Figura 3, exibe uma distribuição levemente assimétrica. Observa-se que a média (20,15) é próxima da mediana (20,00), mas ambas localizam-se mais próximas do primeiro quartil (18,00), o que indica uma assimetria à direita. O intervalo interquartil (IQR) é de 5,25, sugerindo uma dispersão moderada entre os valores centrais. Esse padrão é confirmado pelo coeficiente de variação de 22%, que reforça a existência de uma variabilidade um pouco mais elevada em comparação com outras variáveis do estudo. Foram observados 2 pontos discrepantes nesta variável, abaixo da calda inferior.

A seguir, é apresentada a análise de correlação entre as covariáveis e a variável resposta, com o objetivo de identificar quais relações lineares podem contribuir de forma mais significativa para a explicação do modelo de regressão.




Figura 4: Gráficos de correlação das covariáveis e a variável explicativa - Dados fuel2001

Tabela 2: Tabela de correlações entre as variáveis - dados fuel2001

Correlações	Fuel	Dlic	Income	Miles	Tax
Fuel	1,000	0,468	-0,464	0,208	-0,259
Dlic	0,468	1,000	-0,176	-0,212	-0,085
Income	-0,464	-0,175	1,000	-0,135	-0,010
Miles	0,207	-0,212	-0,135	1,000	-0,064
Tax	-0,259	-0,085	-0,010	-0,064	1,000

No quadro (a) da Figura 4, observa-se a correlação entre as variáveis *Fuel* e *Dlic*. Nota-se uma relação positiva entre elas: à medida que uma aumenta, a outra tende a aumentar também. Essa correlação é considerada moderada, com coeficiente de 0,468, conforme apresentado na Tabela 2. Além disso, os pontos se distribuem seguindo um padrão que sugere uma tendência linear. O gráfico também revela a presença de um outlier, o que indica a possibilidade de se aplicar transformações nos dados para melhorar

o ajuste do modelo de regressão.

Já no quadro (b), observa-se a relação entre as variáveis *Fuel* e *Income*. Embora o gráfico apresente um outlier, de forma geral os pontos seguem uma tendência linear, o que sugere a possibilidade de aplicar ou não transformações nas variáveis, dependendo da avaliação do ajuste. A relação é linear negativa, indicando que, à medida que a média de combustível vendido diminui, a renda per capita tende a aumentar. De acordo com a Tabela 2, o coeficiente de correlação entre essas variáveis é de -0,464, sendo também classificado como moderado.

No gráfico apresentado no quadro (c), observa-se a correlação entre as variáveis *Fuel* e *Miles*. Verifica-se que essa relação é bastante fraca, com os dados concentrados em uma única região do gráfico, sem indícios claros de um padrão linear. De acordo com a Tabela 2, o coeficiente de correlação é de apenas 0,207, o que confirma a baixa associação linear entre essas variáveis e pode indicar a necessidade de aplicar transformações para melhorar o ajuste do modelo.

Finalizando, no quadro (d), observa-se a correlação entre as variáveis *Fuel* e *Tax*. Verifica-se uma relação negativa, embora pouco expressiva, indicando que, à medida que a média de combustível vendido diminui, a taxa de gasolina tende a aumentar. Segundo a Tabela 2, o coeficiente de correlação é de -0,259, sendo classificado como baixo. Além disso, o gráfico revela a presença de alguns pontos discrepantes, distribuídos de forma relativamente dispersa, o que pode sugerir variações extremas pontuais e possíveis impactos no ajuste do modelo.

2.1 Transformações de variáveis

Seguindo o raciocínio da Seção 2, verificou-se que seria adequado testar algumas transformações nas variáveis, a fim de melhorar a relação linear entre a variável resposta e as covariáveis. Para isso, aplicaram-se transformações logarítmicas tanto na variável resposta quanto em algumas covariáveis selecionadas. Foram elaborados novos gráficos de dispersão e recalculados os coeficientes de correlação para verificar a melhoria do ajuste. A seguir, são apresentados apenas os resultados das transformações consideradas mais relevantes e eficazes para o refinamento do modelo.




Figura 5: Gráficos de correlação das covariáveis e a variável explicativa - Dados fuel2001

No primeiro quadro, apresenta-se a correlação entre $\log(Fuel)$ e $\log(Dlic)$, resultado da aplicação da transformação logarítmica em ambas as variáveis para melhorar a linearidade e a adequação do modelo. Observa-se que a relação permanece positiva: quando $\log(Fuel)$ aumenta, $\log(Dlic)$ também tende a aumentar. A associação linear entre as variáveis tornou-se mais evidente, com o coeficiente de correlação de Pearson calculado em 0,531, sendo classificado como moderado. Ainda assim, nota-se a presença de alguns pontos discrepantes (outliers), que podem impactar a qualidade do ajuste.

No quadro (b), apresenta-se a correlação entre $\log(Fuel)$ e $Income$, transformação realizada com o objetivo de tornar a relação entre as variáveis mais linear. Observa-se que, mesmo após a transformação, a relação permaneceu negativa: quando a variável $\log(Fuel)$ diminui, a variável $Income$ tende a aumentar. O coeficiente de correlação de Pearson passou a -0,472, sendo considerado moderado e ligeiramente mais forte do que o valor obtido antes da transformação. Ainda é possível identificar alguns pontos atípicos (outliers), que podem influenciar o ajuste do modelo.

No quadro (c), apresenta-se a correlação entre as variáveis transformadas $\log(Fuel)$

e $\log(Miles)$, transformação que resultou em uma melhoria na linearização e contribuiu para uma adequação mais consistente do modelo. Observa-se uma diferença significativa após a aplicação do logaritmo: o coeficiente de correlação de Pearson passou a 0,465, indicando uma relação positiva. Assim, quando a variável $\log(Fuel)$ aumenta, a variável $\log(Miles)$ também tende a aumentar. Ainda é possível identificar a presença de alguns outliers, que podem impactar o ajuste final.

No quadro (d), foram aplicadas transformações à relação entre as variáveis, mas constatou-se que a melhor opção permaneceu sendo o modelo sem transformação. Dessa forma, manteve-se uma relação linear negativa, ainda que de baixa magnitude, com um coeficiente de correlação de -0,259, classificado como baixo.

3 Seleção de modelos

Dando continuidade às análises realizadas nas Seções 2 e 2.1, esta etapa tem como objetivo selecionar o modelo mais adequado e parcimonioso, de acordo com os critérios discutidos anteriormente. Para isso, utilizam-se três métodos clássicos de seleção de variáveis: passo à frente, passo à trás e passo a passo.

- **Passo à frente (forward):** O procedimento inicia-se com um modelo nulo, contendo apenas o intercepto, e adiciona-se uma variável por vez, de acordo com o critério de melhoria do ajuste.
- **Passo à trás (backward):** Parte-se do modelo completo, com todas as variáveis incluídas, e elimina-se uma variável por vez, buscando simplificar o modelo sem perda significativa de qualidade de ajuste.
- **Passo a passo (stepwise):** Combina as duas abordagens anteriores, permitindo tanto a inclusão quanto a exclusão de variáveis em cada etapa, visando identificar o conjunto de covariáveis que minimize o critério de informação selecionado.

Neste trabalho, foi utilizado o método passo a passo (stepwise), por permitir maior flexibilidade na escolha do conjunto final de variáveis e possibilitar a comparação de diferentes especificações para obtenção do modelo mais parcimonioso possível.

Considerando o critério de informação de Akaike (AIC) como principal medida de avaliação dos modelos, foram testadas diferentes especificações, incluindo o modelo completo sem transformações e versões completas com transformações logarítmicas em algumas variáveis, visando melhorar o ajuste e a linearidade. Em ambas as situações, o AIC indicou que o modelo completo, sem exclusão de covariáveis, apresentou o melhor desempenho para explicar a variável resposta. Ainda assim, foram selecionados outros modelos adicionais que também apresentaram valores de AIC satisfatórios e próximos

do mínimo, com o objetivo de compará-los quanto à robustez e à parcimônia. Assim, definiu-se o conjunto final de modelos a serem ajustados e analisados nesta etapa.

Tabela 3: Modelos candidatos

Modelo	Resposta	Covariáveis
1	Fuel	Dlic,Income,Miles e Tax
2	Fuel	Dlic,Income e Miles
3	$\log(Fuel)$	$\log(Dlic)$,Income,Miles e Tax
4	$\log(Fuel)$	Dlic, Income, Miles e Tax
5	$\log(Fuel)$	Dlic,Income, $\log(Miles)$ e Tax
6	$\log(Fuel)$	$\log(Dlic)$, Income e Miles

4 Análise diagnóstica

4.1 Fuel x Dlic,Income,Miles e Tax


Tabela 4: Ajuste do modelo Fuel x Dlic,Income,Miles e Tax

Coeficientes	Estimativas	Erro padrão	Estatística-t	P-valor
Intercepto	0,3840	0,1658	2,316	0,0250
Dlic	0,5353	0,0137	3,898	0,0003
Income	-0,000007	0,000002	-3,236	0,0022
Miles	0,00000040	0,00000018	2,144	0,0373
Tax	-0,004115	0,002107	-1,952	0,0569
R^2	0.4755			
R^2_{ajustado}	0.4299			


Na Tabela 6 observa-se que, ao nível de significância de 5%, apenas a variável *Tax* não é estatisticamente significativa ($p = 0,0569$), estando ligeiramente acima do limite. As demais variáveis são significativas, contribuindo para explicar a variabilidade de *Fuel*. O modelo apresenta um R^2_{ajustado} de aproximadamente 43%, indicando que uma parcela moderada da variabilidade da variável resposta é explicada pelas variáveis independentes. Apesar de não ser um valor elevado, pode ser considerado razoável para dados deste tipo. Observa-se ainda que as variáveis *Dlic* e *Miles* têm efeitos positivos, enquanto *Income* e *Tax* possuem efeitos negativos. Recomenda-se, por fim, analisar os resíduos e verificar a presença de multicolinearidade, além de avaliar a permanência de *Tax* no modelo.

4.1.1 Suposições e análise diagnóstica


Após o ajuste do modelo, é necessário verificar se as suposições da regressão linear são atendidas, a fim de garantir que o modelo seja parcimonioso e confiável. Para isso, vamos avaliar a normalidade dos resíduos, a não correlação e a homocedasticidade dos mesmos.




(a) Envelope distribuição normal



(b) Envelope distribuição t



(c) Resíduos x Valores ajustados



(d) Resíduos x Índice

Pelo gráfico do quadro (a), observa-se que os resíduos não se desviam de forma significativa do envelope, indicando que seguem aproximadamente uma distribuição normal. Essa conclusão é reforçada pelo gráfico do quadro (b), em que os pontos permanecem próximos da reta de referência e dentro do envelope, confirmando que o modelo satisfaz a suposição de normalidade dos resíduos.

No quadro (c), verifica-se a homocedasticidade do modelo. Observa-se que os resíduos estão dispersos aleatoriamente em torno de zero, embora haja uma leve concentração entre os valores ajustados de 0,60 e 0,70. Não se identifica uma tendência específica ou padrão sistemático, o que indica variância aproximadamente constante. Nota-se também a presença de alguns outliers acima e abaixo das linhas de controle (linhas

vermelhas), mas eles não parecem comprometer a suposição de homocedasticidade.

No quadro (d), observa-se a autocorrelação dos erros. O gráfico mostra que os resíduos estão bem dispersos ao longo do índice, sem apresentar tendência. Essa dispersão aleatória reforça a suposição de independência dos erros, indicando que não há relação sistemática entre as observações.

Assim, conclui-se que o modelo atende às principais suposições da regressão linear. No entanto, é necessário verificar também se há indícios de multicolinearidade quase exata entre as variáveis explicativas. Assim calcula-se a multicolinearidade da seguinte forma:

$$\text{VIF}_j = \frac{1}{1 - R_j^2}, \quad j = 1, \dots, k$$

Em que k representa o número de variáveis explicativas, excluindo o intercepto, e R_j^2 é o coeficiente de determinação obtido na regressão auxiliar da variável x_j sobre as demais covariáveis do modelo.

Na prática, valores de VIF superiores a 5 (equivalente a $R_j^2 = 0,8$) indicam forte correlação entre as variáveis, sugerindo que o coeficiente estimado de x_j e seu erro padrão podem estar distorcidos. Portanto, VIFs elevados são evidências de multicolinearidade quase exata, o que compromete a precisão e a interpretação dos parâmetros do modelo.

Tabela 5: Fatores de Inflação da Variância (VIF) das Covariáveis do Modelo

	VIF
Dlic	1,109
Income	1,068
Miles	1,091
Tax	1,016

Como observado na Tabela 19, os valores dos VIFs não são elevados, situando-se entre 1,01 e 1,10. Isso indica que não há indícios de multicolinearidade exata ou quase exata entre as covariáveis do modelo.


4.1.2 Alavancagem e pontos de influencia

Após o ajuste do modelo de regressão linear múltipla, é fundamental realizar uma análise de diagnóstico para identificar possíveis pontos de alavancagem e pontos de influência, que podem comprometer a qualidade das estimativas.

Os pontos de alavancagem referem-se a observações que apresentam valores extremos em relação às variáveis explicativas. Esses pontos têm o potencial de exercer maior

peso sobre o ajuste da reta, pois podem “puxar” a linha de regressão em direção a si.

Figura 6: Gráfico de Alavanca



Pelo gráfico de alavancagem, é possível identificar apenas uma observação com valor claramente extremo, a observação 44, e três valores considerados com uma alavancagem moderada, 2, 7 e 9. Diante disso, recomenda-se uma investigação mais detalhada sobre as observações, a fim de avaliar seu impacto no ajuste do modelo.

Os pontos de influência são observações que, em sua maioria possuem alta alavancagem, têm grande impacto sobre os coeficientes estimados e os valores ajustados; ou seja, sua presença ou ausência pode alterar significativamente o modelo.




Figura 7: Gráficos de distancia de Cook e DFFITS

Nos gráficos de DFFITS e Distância de Cook, é possível observar novamente

as observações 2 e 9 destacando-se como pontos influentes. Diante disso, recomenda-se realizar uma investigação mais detalhada sobre essas observações, a fim de avaliar se sua presença compromete o ajuste do modelo.




Figura 8: Gráficos DFBETAS para cada beta

Nos gráficos de DFBETAS, observam-se também as observações 2, 9, 10, 12 e 24 aparecendo de forma recorrente em todos os coeficientes, o que reforça ainda mais os indícios de que esses pontos exercem influência significativa sobre o modelo.

4.1.3 Investigação de pontos influentes

Como visto anteriormente, as observações 2, 9, 10, 12, 24, 33 e 51 foram identificadas como possíveis pontos influentes no modelo. Diante disso, será realizada uma investigação complementar por meio da exclusão individual dessas observações, com o objetivo de avaliar o impacto de cada uma no ajuste e na robustez dos coeficientes estimados.

Tabela 6: Ajsute do modelo Fuel x Dlic,Income,Miles e Tax

Coeficientes	Estimativas	Erro padrão	Estatística-t	P-valor
Intercepto	0,561	0,103	5,411	< 0,0001
Dlic	0,404	0,098	4,107	0,0001
Income	-0,000005	0,000001	-4,419	< 0,0001
Miles	0,00000014	0,00000011	1,129	0,2028
Tax	-0,0078	0,0013	-5,928	< 0,0001
R^2	0,6517			
R^2_{ajustado}	0,616			

Ao analisar o modelo ajustado sem as observações identificadas como influentes, observa-se que a significância estatística do intercepto, bem como das variáveis *Dlic*, *Income* e *Tax*, apresentou aumento razoável, indicando maior robustez na estimativa desses coeficientes. Além disso, embora as estimativas dos parâmetros tenham sofrido algumas variações, tais mudanças não foram substanciais a ponto de alterar a interpretação geral do modelo. Por outro lado, os coeficientes de determinação R^2 e R^2_{ajustado} apresentaram um acréscimo expressivo de aproximadamente 18%, o que sugere uma melhora na qualidade do ajuste após a exclusão dos pontos de influência.

4.2 Fuel x Dlic,Income e Miles

A seguir, apresenta-se o ajuste do modelo com a variável resposta *Fuel* em função de *Dlic*, *Income* e *Miles*, a fim de avaliar se este é válido para uso.

Tabela 7: Ajsute do modelo Fuel x Dlic,Income e Miles


Coeficientes	Estimativas	Erro padrão	Estatística-t	P-valor
Intercepto	0,266	0,159	1,678	0,100
Dlic	0,564	0,140	4,017	0,0002
Income	-0,000007	0,000002	-3,066	0,003
Miles	0,0000004	0,0000002	2,265	0,028
R^2	0,4321			
R^2_{ajustado}	0,3958			

Pela Tabela 7, observa-se que o intercepto, ao nível de significância de 5%, não é significativo, enquanto as covariáveis são todas significativas. As estimativas dos coeficientes de *Income* e *Miles* são baixas, indicando que o efeito prático dessas variáveis sobre a resposta não é tão relevante. Verifica-se também que o R^2 é igual a 0,4321 e o R^2_{ajustado}


é de 0,39, o que significa que apenas 39% da variabilidade da resposta é explicada pelo modelo. Diante disso, conclui-se que este modelo não é adequado para representar os dados de forma satisfatória.

4.2.1 Suposições e análise diagnóstica


Para complementar a análise, é necessário verificar se o modelo atende às suposições da regressão linear. Para isso, analisam-se a normalidade, a não correlação e a homocedasticidade dos erros.




(a) Envelope distribuição normal



(b) Envelope distribuição t



(c) Resíduos x Valores ajustados



(d) Resíduos x Índice

Observa-se, pelo gráfico envelope no quadro (a), que os dados seguem uma distribuição normal, pois praticamente não apresentam desvios em relação ao envelope. Essa análise é confirmada pelo envelope da distribuição t no quadro (b), onde também é possível verificar a ausência de desvios significativos, com exceção de dois pontos discrepantes: os pontos 2 e 51.

No gráfico de homocedasticidade apresentado no quadro (c), percebe-se que os dados estão minimamente dispersos, embora haja uma leve concentração para os maiores

valores ajustados. Apesar dessa pequena concentração, os dados indicam uma variância aproximadamente constante, com apenas um ponto fora dos limites.

No quadro (d), visualiza-se que os resíduos estão bem distribuídos em relação ao índice das observações, não indicando tendência aparente e apresentando apenas um ponto fora dos limites. Dessa forma, pode-se afirmar que não há indícios de correlação entre os erros.

Além disso, é necessário verificar se há multicolinearidade quase exata entre as covariáveis, o que pode ser avaliado por meio dos VIFs (Variance Inflation Factors). Na prática, valores de VIF superiores a 5 (equivalente a $R_j^2 = 0,8$) indicam forte correlação entre as variáveis, sugerindo que o coeficiente estimado de x_j e seu erro padrão podem estar distorcidos. Portanto, VIFs elevados são evidências de multicolinearidade quase exata, o que compromete a precisão e a interpretação dos parâmetros do modelo.

Tabela 8: Fatores de Inflação da Variância (VIF) das Covariáveis do Modelo

	VIF
$\log(Dlic)$	1,108
Income	1,096
Miles	1,066
Tax	1,082

A partir dos valores de VIF (Variance Inflation Factor) calculados, não foi possível identificar indícios de multicolinearidade quase exata entre as covariáveis do modelo. Todos os VIFs apresentaram valores inferiores ao limite crítico de 5, indicando baixa correlação linear entre as variáveis explicativas. Isso sugere que os coeficientes estimados não estão inflacionados pela presença de redundância entre as variáveis, contribuindo para maior estabilidade e confiabilidade nas interpretações dos parâmetros do modelo.

Embora o modelo atenda adequadamente às suposições clássicas da regressão linear (como normalidade dos resíduos, homocedasticidade e ausência de autocorrelação), ele não apresenta um bom ajuste em comparação com os demais modelos analisados. Essa limitação é evidenciada pelo seu baixo ($R_{ajustado}^2$), que indica uma menor capacidade explicativa após o ajuste pelo número de parâmetros.

Além disso, o valor do AIC (Critério de Informação de Akaike) obtido para esse modelo foi inferior ao do modelo completo, que inclui todas as covariáveis disponíveis. Esses resultados sugerem que, apesar de estatisticamente válido, o modelo em questão não é o mais eficiente em termos de qualidade de ajuste e parcimônia, sendo, portanto, preterido na escolha final.

4.3 $\log(\text{Fuel}) \times \log(\text{Dlic})$, **Income**, **Miles** e **Tax**

A seguir segue o ajuste do terceiro modelo candidato, $\log(\text{Fuel}) \times \log(\text{Dlic})$, *Income*, *Miles* e *Tax*.

Tabela 9: Ajuste do modelo $\log(\text{Fuel}) \log(\text{Dlic})\text{Income}, \text{Miles}$ e *Tax*


Coefficientes	Estimativas	Erro padrão	Estatística-t	P-valor
Intercepto	0,009	0,139	0,071	0,943
$\log(\text{Dlic})$	1,002	0,213	4,703	< 0,0001
Income	-0,000012	0,0000038	-3,211	0,002
Miles	0,0000008	0,0000003	2,509	0,015
Tax	0,005	0,003	-1,552	0,127
R^2	0,522			
R^2_{ajustado}	0,4804			

A partir da Tabela 9, observa-se que as estimativas dos coeficientes das variáveis explicativas não apresentam magnitudes elevadas, especialmente para as variáveis *Income*, *Miles* e *Tax*. Ao nível de significância de 5%, o modelo indica que o intercepto e a variável *Tax* não são estatisticamente significativos, diferentemente das demais covariáveis.


Além disso, o coeficiente de determinação ajustado (R^2_{ajustado}) é igual a 0,4804, o que indica que aproximadamente 48% da variabilidade da variável resposta é explicada pelo modelo ajustado.

4.3.1 Suposições e análise diagnóstica


Seguindo a análise realizada até o momento, torna-se necessário testar as suposições do modelo de regressão linear para que se possa afirmar, com maior rigor, que o modelo ajustado é de fato adequado. A verificação dessas suposições (como normalidade dos resíduos, homocedasticidade e independência) é fundamental para garantir a validade estatística das estimativas e a confiabilidade das inferências realizadas a partir do modelo.




(e) Envelope distribuição normal



(f) Envelope distribuição t



(g) Resíduos x Valores ajustados



(h) Resíduos x Índice

No gráfico envelope referente à distribuição normal, observa-se que os dados estão majoritariamente contidos dentro do envelope, com poucos desvios em relação às linhas de referência, o que indica uma tendência de normalidade nos resíduos. Essa evidência é reforçada pelo gráfico baseado na distribuição t, no qual os pontos se alinham ainda mais claramente dentro do envelope, confirmando o comportamento aproximadamente normal. No entanto, é possível identificar dois pontos mais discrepantes, correspondentes às observações 2 e 9.

No quadro (g), analisa-se a variância dos resíduos em relação aos valores ajustados. Observa-se que os pontos estão razoavelmente bem distribuídos ao longo do eixo horizontal, embora exista uma concentração maior de observações entre os valores ajustados de aproximadamente -0,6 a -0,4. Ainda assim, os dados indicam evidências de homocedasticidade, uma vez que não se observa um padrão de aumento ou diminuição da variância. É possível notar a presença de alguns pontos que ultrapassam os limites de referência, sugerindo possíveis observações atípicas.

Já no gráfico apresentado no quadro (h), os resíduos estão distribuídos de forma aparentemente aleatória em relação ao índice das observações, sem sinais evidentes de

tendência ou padrão sequencial. Isso fornece indícios de que a suposição de independência dos erros é plausível. No entanto, também se observam algumas discrepâncias nas extremidades, com pontos que ultrapassam as linhas de referência, o que pode indicar a presença de valores extremos ou influentes.

É importante verificar se há multicolinearidade quase exata entre as covariáveis do modelo. Para isso, calcula-se o Valor de Inflação da Variância (VIF — *Variance Inflation Factor*), que permite identificar a presença de correlação linear entre as variáveis explicativas. Na prática, valores de VIF superiores a 5 (equivalentes a um $R_j^2 = 0,8$) indicam forte correlação entre as covariáveis, sugerindo que o coeficiente estimado de x_j e seu erro padrão podem estar inflacionados.

Tabela 10: Fatores de Inflação da Variância (VIF) das Covariáveis do Modelo


	VIF
$\log(Dlic)$	1,108
Income	1,076
Miles	1,083
Tax	1,015

A partir da Tabela, observa-se que os valores dos VIFs (Variance Inflation Factors) são baixos, permanecendo abaixo do limite de referência adotado (geralmente igual a 5). Isso indica que não há evidências de multicolinearidade quase exata entre as covariáveis no modelo ajustado, o que reforça a confiabilidade das estimativas obtidas.

4.3.2 Alavancagem e pontos de influencia

Seguindo a análise, é fundamental investigar a presença de possíveis pontos de alavancagem e pontos de influência, uma vez que tais observações podem comprometer a qualidade do ajuste do modelo. A identificação desses pontos permite avaliar a robustez das estimativas e garantir que o modelo não esteja sendo excessivamente influenciado por observações atípicas ou com grande capacidade de alterar os coeficientes estimados.

Figura 9: Gráfico de Alavanca



Na Figura 9, é possível identificar quatro observações que se destacam como potenciais pontos de alavancagem: 44, 9, 7 e 2. Dentre elas, a observação 44 pode ser classificada como um ponto de alavanca forte, enquanto as demais (9, 7 e 2) apresentam alavancagem moderada. Esses pontos merecem atenção, pois podem exercer influência considerável sobre o ajuste do modelo.




Figura 10: Gráficos de distancia de Cook e DFFITS

Nos gráficos de diagnóstico de influência, especificamente os gráficos de DFFITS e Distância de Cook, observa-se a recorrência de pontos previamente identificados com alavancagem moderada, como as observações 2 e 9. Além desses, identificam-se outros cinco pontos como possíveis influentes no modelo: 10, 12, 24, 33 e 51. A presença desses pontos sugere que determinadas observações podem estar exercendo impacto relevante

sobre os coeficientes estimados, sendo, portanto, recomendável uma investigação mais detalhada quanto à sua influência no ajuste do modelo.




Figura 11: Gráficos DFBETAS para cada beta

Pelo gráfico de influência baseado nos valores de DFBETAS, observa-se novamente a presença dos mesmos pontos identificados nos gráficos anteriores (2, 9, 10, 12, 24, 33 e 51), o que reforça a evidência de que essas observações exercem influência significativa sobre os coeficientes do modelo. Diante disso, recomenda-se uma análise mais aprofundada, avaliando o comportamento do modelo ajustado na ausência desses pontos, a fim de verificar a robustez das estimativas e a estabilidade dos parâmetros.

4.3.3 Investigação dos pontos influentes

Agora vamos entender como fica o modelo com a exclusão desses pontos encontrados anteriormente, 2, 9, 10, 12, 24, 33 e 51.

Tabela 11: Ajsute do modelo $\log(\text{Fuel}) \log(\text{Dlic})\text{Income}, \text{Miles}$ e Tax sem os dados 2, 9, 10, 12, 24, 33 e 51

Coeficientes	Estimativas	Erro padrão	Estatística-t	P-valor
Intercepto	0,008	0,078	1,015	0,316
$\log(\text{Dlic})$	0,617	0,147	4,190	0,0001
Income	-0,000008	0,000002	-4,440	< 0,0001
Miles	0,0000002	0,0000001	1,323	0,193
Tax	0,012	0,002	-5,820	< 0,0001
R^2	0,6509			
R^2_{ajustado}	0,6151			

Após a retirada dos pontos influentes identificados, o modelo ajustado não apresentou mudanças expressivas na significância das covariáveis, exceto pela variável *Miles*, que deixou de ser estatisticamente significativa ao nível de 5%. Observa-se, entretanto, um aumento considerável nos valores de R^2 e R^2_{ajustado} , ambos superiores a 15%, indicando que a variabilidade da resposta passou a ser melhor explicada pelo modelo ajustado sem os pontos influentes. Ainda assim, essa melhora não é suficiente para afirmar que o novo modelo é substancialmente mais eficiente.

4.4 $\log(\text{Fuel}) \text{Dlic}, \text{Income}, \text{Miles}$ e Tax

Esta seção tem como objetivo avaliar se o ajuste do modelo $\log(\text{Fuel})$ em função das variáveis *Dlic*, *Income*, *Miles* e *Tax* é, de fato, adequado e válido para explicar a variável resposta.

Tabela 12: Ajsute do modelo $\log(\text{Fuel}) \text{Dlic}, \text{Income}, \text{Miles}$ e Tax


Coeficientes	Estimativas	Erro padrão	Estatística-t	P-valor
Intercepto	-1,066	0,296	-3,596	< 0,0001
Dlic	1,088	0,245	4,430	< 0,0001
Income	-0,000012	0,000004	-3,279	0,001
Miles	0,0000008	0,0000003	2,474	0,017
Tax	-0,0057	0,0037	-1,515	0,136
R^2	0,5038			
R^2_{ajustado}	0,4606			

Segundo o ajuste do modelo apresentado na Tabela 12, observa-se que todas as variáveis são estatisticamente significativas, exceto a variável *Tax*, que, ao nível de


significância de 5%, não apresenta evidência suficiente para ser considerada relevante no modelo. As variáveis **Income** e **Miles**, por apresentarem estimativas de coeficientes com magnitudes relativamente baixas, indicam uma influência menor sobre a variável resposta. Ademais, os valores de R^2 (0,5038) e R^2_{ajustado} (0,4606) mostram que aproximadamente 46,06% da variabilidade da resposta é explicada pelo modelo, o que pode ser considerado um bom resultado para dados observacionais.

4.4.1 Suposições e análise diagnóstica


Apesar do modelo ter apresentado bons ajustes no tópico anterior, para verificar se ele é, de fato, adequado, é fundamental testar as suposições do modelo de regressão linear. Entre elas: a normalidade dos resíduos, a homocedasticidade (constância da variância dos erros) e a ausência de autocorrelação entre os resíduos.




(a) Envelope distribuição normal



(b) Envelope distribuição t



(c) Resíduos x Valores ajustados



(d) Resíduos x Índice

Pelo gráfico de distribuição normal, observa-se que a maioria dos pontos se encontra dentro do envelope, indicando que os resíduos seguem, em geral, uma distribuição aproximadamente normal. No entanto, alguns pontos se desviam levemente do envelope,

o que é confirmado também pelo gráfico da distribuição t , que mostra os pontos ao redor da reta central e, majoritariamente, dentro dos limites esperados. Destacam-se, nesse caso, duas observações mais atípicas: as de número 2 e 9.

No gráfico utilizado para verificar a homocedasticidade, é possível observar que os resíduos estão relativamente bem distribuídos, embora apresentem uma leve concentração no lado direito do gráfico. Alguns pontos aparecem fora dos limites de referência, mas, de forma geral, os indícios de homocedasticidade dos erros permanecem presentes.

Por fim, o gráfico do quadro (d), utilizado para avaliar a independência dos erros, apresenta os valores dos resíduos bem distribuídos ao longo dos índices. Embora haja alguns pontos fora dos limites inferior e superior, e padrões leves possam ser percebidos, não há indícios fortes de violação da suposição de independência dos erros.

É essencial verificar a existência de multicolinearidade entre as variáveis explicativas do modelo, ou seja, se há uma correlação linear elevada entre elas. Para essa avaliação, utiliza-se o Fator de Inflação da Variância (VIF — *Variance Inflation Factor*), que quantifica o quanto a variância do coeficiente estimado de uma variável aumenta devido à sua correlação com as demais. De modo geral, valores de VIF acima de 5 (correspondentes a um $R_j^2 = 0,8$) são indicativos de uma multicolinearidade elevada, o que pode comprometer a precisão das estimativas dos coeficientes e inflacionar seus erros padrão.

Tabela 13: Fatores de Inflação da Variância (VIF) das Covariáveis do Modelo


	VIF
Dlic	1,109
Income	1,068
Miles	1,091
Tax	1,016

Observa-se que nenhum dos valores apresentados na Tabela acima ultrapassa o limite de 5. Portanto, pode-se concluir que não há evidências de multicolinearidade quase exata entre as covariáveis do modelo ajustado.

4.4.2 Alavancagem e pontos de influencia

Após as análises anteriores, torna-se de extrema importância identificar a presença de pontos de alavancagem e de influência no modelo, bem como verificar se tais observações exercem impacto significativo nos resultados ajustados.

Figura 12: Gráfico de Alavanca



Observa-se que o gráfico de alavancagem apresentado identifica quatro possíveis pontos com alta alavanca nos valores ajustados: as observações 44, 9, 7 e 2. A observação 44 se destaca como um possível ponto de alavancagem forte, enquanto as demais podem ser classificadas como pontos de alavancagem moderada.






Figura 13: Gráficos de distancia de Cook e DFFITS


Observa-se, pelos gráficos de DFFITS e Distância de Cook apresentados acima, que os pontos 2 e 9 também se destacam como possíveis observações influentes. Além deles, identificam-se mais cinco pontos com potencial influência sobre o modelo: 10, 12, 24, 33 e 51. Diante disso, é necessário realizar uma investigação mais detalhada para avaliar se essas observações impactam significativamente os resultados do modelo ajustado.




(a) Beta 0



(b) Beta 1



(c) Beta 2



(d) Beta 3

Figura 14: Gráficos DFBETAS para cada beta

Pelos gráficos de DFBETAS, é possível observar os mesmos pontos identificados anteriormente nos gráficos de DFFITS e Distância de Cook, reforçando a evidência de que se tratam de observações influentes. Dessa forma, torna-se necessário investigar o impacto desses pontos no modelo, por meio de sua exclusão e posterior análise do ajuste.

4.4.3 Investigação de pontos influentes

A partir de agora entende-se como fica o ajuste sem os pontos observados na última sessão.

Tabela 14: Ajsute do modelo $\log(\text{Fuel})$ Dlic,Income,Miles e Tax sem os pontos sem os pontos 2, 9, 10, 12, 24, 33 e 51

Coeficientes	Estimativas	Erro padrão	Estatística-t	P-valor
Intercepto	-0,5917	0,1703	-3,475	0,001
Dlic	0,6734	0,1617	4,166	0,0001
Income	-0,000008	0,000002	-4,436	< 0, 0001
Miles	0,0000002	0,0000001	1,324	0,193
Tax	-0,0126	0,0021	-5,818	< 0, 0001
R^2	0,6496			
R^2_{ajustado}	0,6137			

Na Tabela 14, apresenta-se o modelo ajustado após a exclusão das observações influentes. Nota-se que os níveis de significância do intercepto e das covariáveis diminuíram levemente, mas sem alterações substanciais. Além disso, ao nível de 5% de significância, a variável Tax deixou de ser estatisticamente significativa. Observa-se ainda um aumento considerável nos valores de R^2 e R^2_{ajustado} , sendo que, neste novo ajuste, aproximadamente 61% da variabilidade da resposta é explicada pelo modelo.

4.5 $\log(\text{Fuel})$ Dlic,Income,log(Miles) Tax

Apresenta-se, a seguir, o modelo $\log(\text{Fuel})$ em função de Dlic, Income, $\log(\text{Miles})$ Tax, com o objetivo de verificar se o ajuste do modelo é válido.

Tabela 15: Ajsute do modelo $\log(\text{Fuel})$ Dlic,Income,log(Miles) Tax

Coeficientes	Estimativas	Erro padrão	Estatística-t	P-valor
Intercepto	-1,563	0,341	-4,571	< 0, 0001
Dlic	0,957	0,225	4,249	< 0, 0001
Income	-0,00001	0,000004	-2,794	0,007
$\log(\text{Miles})$	0,056	0,016	3,473	0,001
Tax	-0,0059	0,0035	-1,665	0,102
R^2	0,5546			
R^2_{ajustado}	0,5158			

Pela tabela de ajuste apresentada, observa-se que, ao nível de significância de 5%, quase todas as variáveis são estatisticamente significativas para o modelo, com exceção da variável Tax. As estimativas dos coeficientes das variáveis Income e Tax possuem magnitudes muito pequenas, o que sugere que essas variáveis exercem menor influência


sobre a variável resposta.

Os valores de R^2 e R^2_{ajustado} indicam a proporção da variabilidade da resposta explicada pelo modelo ajustado, sendo essa igual a 51,58%, o que caracteriza um ajuste razoável.


Apesar desses resultados, é imprescindível que o modelo também atenda às suposições da regressão linear — normalidade dos resíduos, ausência de autocorrelação e homocedasticidade — para que possa ser considerado estatisticamente válido.

4.5.1 Suposições e análise diagnóstica


Nesta subseção, será verificado se o modelo é realmente válido para explicar a variável resposta, por meio da análise das suposições do modelo de regressão linear.




(a) Envelope distribuição normal



(b) Envelope distribuição t



(c) Resíduos x Valores ajustados



(d) Resíduos x Índice

Nos gráficos da distribuição normal e da distribuição t, observa-se que os resíduos não se desviam significativamente do envelope, indicando aderência à normalidade. Embora alguns pontos, como as observações 2 e 33, apresentem desvios, não há indícios

suficientes para rejeitar a suposição de normalidade dos erros.

Para verificar a homocedasticidade, analisou-se o gráfico dos resíduos studentizados em função dos valores ajustados. Nota-se que os resíduos estão razoavelmente dispersos ao longo do eixo horizontal, com leve concentração entre os valores -0,6 e -0,4, mas sem padrão sistemático evidente. Além disso, apenas três observações estão fora dos limites, o que sugere que a variância dos erros pode ser considerada aproximadamente constante.

Quanto à suposição de ausência de autocorrelação dos erros, o gráfico dos resíduos em função do índice das observações indica que não há tendência clara nem padrão repetitivo. Embora existam três observações fora dos limites de controle, os resíduos parecem distribuídos de forma aleatória, o que sustenta a hipótese de independência entre os erros.

Nesta etapa da análise diagnóstica, é fundamental verificar a presença de multicolinearidade entre as covariáveis do modelo. Esse fenômeno pode comprometer a precisão das estimativas dos coeficientes, inflacionando seus erros padrão e dificultando a interpretação dos efeitos individuais de cada variável explicativa. Para isso, utiliza-se o Fator de Inflação da Variância (VIF — *Variance Inflation Factor*), que quantifica o quanto a variância estimada de um coeficiente aumenta em razão da correlação com as demais variáveis do modelo. De modo geral, valores de VIF superiores a 5 (correspondentes a um R_j^2 de aproximadamente 0,80) são considerados indicativos de multicolinearidade elevada e, portanto, devem ser analisados com atenção.

Tabela 16: Fatores de Inflação da Variância (VIF) das Covariáveis do Modelo


	VIF
Dlic	1,040
Income	1,132
$\log(Miles)$	1,099
Tax	1,010

A partir da tabela apresentada, observa-se que nenhum dos valores de VIF ultrapassa o limite de 5. Dessa forma, conclui-se que o modelo não apresenta indícios de multicolinearidade quase exata entre as covariáveis.

4.5.2 Alavancagem e pontos de influencia

Nessa sessão o objetivo é verificar a presença de pontos de alavanca e de influência no modelo, uma vez que tais observações podem distorcer os resultados da regressão e comprometer a validade das inferências.

Figura 15: Gráfico de Alavanca



Pelo gráfico de alavancagem, é possível identificar três observações que se destacam como possíveis pontos de alavanca no modelo. A observação 9 se apresenta como um ponto de alavancagem elevada, enquanto as observações 2 e 7 possuem alavancagem moderada. Esses pontos merecem atenção, pois podem exercer influência considerável sobre os valores ajustados da regressão.




Figura 16: Gráficos de distancia de Cook e DFFITS

A partir da análise dos pontos de alavancagem, observa-se que duas das observações identificadas como de alavanca, os pontos 2 e 9, também aparecem nos gráficos de DFFITS e Distância de Cook como possíveis pontos influentes. Essa sobreposição reforça a evidência de que essas observações podem estar exercendo influência indevida sobre os parâmetros do modelo. Além disso, outras observações como os pontos 8, 10,

12, 24, 33 e 51 também foram destacadas nos gráficos de influência, sendo, portanto, necessário investigar com mais profundidade o impacto de cada uma delas sobre o ajuste do modelo.




Figura 17: Gráficos DFBETAS para cada beta

A partir dos gráficos de DFBETAS, é possível identificar novamente os mesmos pontos influentes destacados anteriormente nas demais medidas de influência. Essa recorrência reforça a necessidade de investigação mais aprofundada dessas observações, a fim de compreender se, de fato, exercem impacto relevante sobre os coeficientes estimados. Para isso, realiza-se a comparação entre os ajustes do modelo com e sem essas observações, permitindo avaliar a robustez dos resultados obtidos.

4.5.3 Investigação de pontos influentes

Agora buscamos entender como fica o ajuste sem os pontos observados na última sessão.

Tabela 17: Ajuste do modelo $\log(\text{Fuel})$ Dlic , Income , Miles e Tax sem os pontos sem os pontos 2, 9, 8, 10, 12, 24, 33 e 51

Coeficientes	Estimativas	Erro padrão	Estatística-t	P-valor
Intercepto	-0,7208	0,2587	-2,786	0,0082
Dlic	0,6423	0,1582	4,060	0,0002
Income	-0,000008	0,000002	-4,269	< 0,0001
$\log(\text{Miles})$	0,0159	0,01353	1,167	0,2504
Tax	-0,0126	0,0023	-5,661	< 0,0001
R^2	0,6547			
R^2_{ajustado}	0,6184			

A partir da tabela de ajustes obtida após a retirada das observações potencialmente influentes, observa-se que as estimativas dos coeficientes não apresentaram mudanças significativas, assim como os níveis de significância da maioria das variáveis permaneceram estáveis. A única exceção foi a variável $\log(\text{Miles})$, que deixou de ser estatisticamente significativa no novo ajuste. Além disso, os valores de R^2 e R^2_{ajustado} apresentaram um leve aumento, mas não o suficiente para caracterizar uma melhora substancial no desempenho do modelo.

4.6 $\log(\text{Fuel})$ $\log(\text{Dlic})$ Income e Miles

A seguir, busca-se avaliar se o modelo $\log(\text{Fuel})$ em função de $\log(\text{Dlic})$, Income e Miles apresenta um bom ajuste para explicar a variabilidade da variável resposta.

Tabela 18: Ajuste do modelo $\log(\text{Fuel})$ $\log(\text{Dlic})$ Income e Miles

Coeficientes	Estimativas	Erro padrão	Estatística-t	P-valor
Intercepto	-0,112	0,116	-0,969	0,337
$\log(\text{Dlic})$	1,036	-0,215	4,818	< 0,0001
Income	-0,00001	0,0000039	-3,102	0,00325
Miles	0,0000008	0,0000003	2,618	0,118
R^2	0,4970			
R^2_{ajustado}	0,4649			


Pela Tabela acima, observa-se que os coeficientes das variáveis $\log(\text{Dlic})$ e Income são estatisticamente significativos ao nível de 5%, indicando que contribuem para explicar a variabilidade da resposta. No entanto, apesar da significância estatística, a variável Income , assim como Miles , apresenta coeficiente de baixa magnitude, sugerindo que seu

impacto prático sobre a variável resposta pode ser limitado.


Adicionalmente, os valores de R^2 e R^2_{ajustado} foram de 0,4970 e 0,4649, respectivamente, o que indica que aproximadamente 46,49% da variabilidade da variável resposta é explicada pelo modelo ajustado.

4.6.1 Suposições e análise diagnóstica


Visto que o modelo apresenta, a princípio, um bom ajuste aos dados, é necessário verificar se o mesmo atende às suposições fundamentais da regressão linear, garantindo, assim, a validade das inferências realizadas.




(a) Envelope distribuição normal



(b) Envelope distribuição t



(c) Resíduos x Valores ajustados



(d) Resíduos x Índice

Nos gráficos (a) e (b), que correspondem respectivamente ao envelope de normalidade e ao envelope da distribuição t, observa-se que os resíduos não se desviam significativamente do envelope. Apesar disso, algumas observações, como a 24 e a 51, apresentam leve afastamento, visível especialmente no gráfico da distribuição t. Dessa forma, há indícios de que os resíduos seguem aproximadamente uma distribuição normal.

O gráfico (c), que analisa a homocedasticidade, mostra que os resíduos estão mais concentrados no lado direito do gráfico. No entanto, não se observa um padrão de dispersão nem um número expressivo de pontos fora dos limites de confiança. Assim, há evidências de que os erros possuem variância aproximadamente constante.

O gráfico dos resíduos studentizados em função do índice da observação busca verificar a independência dos erros. Nele, os resíduos se apresentam bem distribuídos ao longo do índice, sem padrão evidente, o que sugere a ausência de autocorrelação entre os erros.

Adicionalmente, é importante verificar se o modelo apresenta multicolinearidade quase exata entre as covariáveis. Para isso, são analisados os valores dos Fatores de Inflação da Variância (VIFs). Na prática, valores de VIF superiores a 5 (equivalentes a $R_j^2 > 0,80$) indicam forte correlação entre as variáveis explicativas, comprometendo a precisão das estimativas dos coeficientes. No presente modelo, os valores de VIF calculados se mantêm abaixo desse limite, não indicando evidência de multicolinearidade severa.

Tabela 19: Fatores de Inflação da Variância (VIF) das Covariáveis do Modelo


	VIF
$\log(Dlic)$	1,096
Income	1,074
Miles	1,075

A partir da tabela apresentada, observa-se que nenhum dos valores de VIF ultrapassa o valor de 5. Dessa forma, conclui-se que o modelo ajustado não apresenta multicolinearidade quase exata entre as covariáveis.

4.6.2 Alavancagem e pontos de influencia

Nesta etapa, analisamos se o modelo ajustado apresenta pontos de alavanca ou pontos de influência que possam exercer impacto significativo sobre os resultados do modelo.

Figura 18: Gráfico de Alavanca



Pelo gráfico de alavancagem, é possível identificar três observações como potenciais pontos de alavanca: a observação 44, classificada como um ponto de alavanca forte, e as observações 9 e 7, consideradas pontos de alavanca moderada. Apesar da identificação inicial desses pontos, é necessário continuar a investigação para compreender o real impacto que exercem sobre o modelo ajustado.






Figura 19: Gráficos de distancia de Cook e DFFITS

Nos gráficos de DFFITS e Distância de Cook, observa-se que a observação 9 aparece em ambos, o que indica que, além de ser um ponto de alavanca, também é um ponto de influência, podendo impactar significativamente o modelo ajustado. Além disso, as observações 2, 12, 24 e 33 também surgem como possíveis pontos influentes. Dessa forma, torna-se necessário investigar esses pontos de forma mais detalhada, a fim de


avaliar seu efeito sobre os resultados do modelo.




(a) Beta 0



(b) Beta 1



(c) Beta 2



(d) Beta 3

Figura 20: Gráficos DFBETAS para cada beta

Pelos gráficos de DFBETAS, é possível identificar os mesmos pontos observados anteriormente como potenciais influentes: as observações 9, 2, 12, 24 e 33. Esses pontos aparecem com destaque em quase todos os coeficientes (β s), sugerindo forte influência nas estimativas do modelo. Diante disso, é fundamental analisar o comportamento do modelo após a exclusão dessas observações, a fim de verificar se de fato exercem influência significativa sobre os resultados e a qualidade do ajuste.

4.6.3 Investigação de pontos influentes

Tabela 20: $\log(\text{Fuel})$ $\log(\text{Dlic})$ Income e Miles sem os pontos sem os pontos 9, 2, 12, 24 e 33

Coeficientes	Estimativas	Erro padrão	Estatística-t	P-valor
Intercepto	-0,1790	0,0939	-1,905	0,0636
$\log(\text{Dlic})$	0,5878	0,2179	2,698	0,010
Income	-0,000009	0,000003	-2,951	0,0051
Miles	0,0000002	0,0000002	1,060	0,2952
R^2	0,2813			
R^2_{ajustado}	0,2300			

A partir da tabela do modelo ajustado, observa-se que os valores das estimativas dos coeficientes não sofreram grandes alterações. A significância das variáveis também se manteve, com $\log(\text{Dlic})$ e Income permanecendo significativas ao nível de 5%. No entanto, os valores de R^2 e R^2_{ajustado} apresentaram uma queda expressiva de aproximadamente 20%, indicando que a variabilidade da resposta passou a ser cerca de 20% menos explicada pelo modelo após a exclusão das observações influentes. Dessa forma, conclui-se que os pontos influentes identificados de fato exercem influência sobre o modelo, especialmente em sua capacidade preditiva.

4.7 Interações de Primeira Ordem

Após a realização de todas as análises — incluindo análise descritiva, transformações, seleção de variáveis com base no critério de AIC, e diagnóstico detalhado de múltiplos modelos — concluiu-se que o modelo mais adequado para explicar a variável $\log(\text{Fuel})$ aquele que inclui como covariáveis: Dlic , Income , $\log(\text{Miles})$ Tax . A partir desse modelo final, passamos a investigar a possibilidade de melhoria do ajuste por meio da inclusão de interações de primeira ordem entre as variáveis explicativas, a fim de verificar se o efeito de uma variável sobre a resposta depende do nível de outra.

As interações de primeira ordem foram consideradas com base na plausibilidade teórica e nas correlações observadas entre as covariáveis. Foram testadas interações entre Dlic e Income , Income e $\log(\text{Miles})$ e também entre Dlic e $\log(\text{Miles})$. Essas combinações foram escolhidas por envolverem variáveis com relação direta à resposta e por possibilitarem interpretações relevantes. O objetivo dessa etapa foi verificar se o efeito de uma variável explicativa sobre o consumo de combustível depende do nível de outra, podendo assim melhorar a capacidade preditiva e interpretativa do modelo.

Tabela 21: Ajsute do modelo $\log(\text{Fuel}) \sim \text{Dlic} + \text{Income} + \log(\text{Miles}) + \text{Tax} + \text{Dlic} * \text{Income} + \text{Dlic} * \log(\text{Miles}) + \text{Dlic} * \text{Tax} + \text{Income} * \log(\text{Miles}) + \text{Income} * \text{Tax} + \log(\text{Miles}) * \text{Tax}$

Coeficientes	Estimativas	Erro padrão	Estatística-t	P-valor
Intercepto	-3,833	3,855	-0,994	0,326
Dlic	1,791	3,177	0,564	0,576
Income	-0,000020	0,000072	-0,281	0,780
$\log(\text{Miles})$	0,4653	0,3028	1,537	0,132
Tax	-0,0056	0,0034	-1,630	0,111
Dlic*Income	0,000072	0,000048	1,501	0,141
Income*log(Miles)	-0,0000053	0,0000049	-1,084	0,248
Dlic*log(Miles)	-0,2935	0,2171	-1,352	0,183
R^2	0,6168			
R^2_{ajustado}	0,5544			

Segundo a tabela acima, nenhuma das interações incluídas no modelo apresentou significância estatística, ou seja, todos os p-valores associados foram superiores a 0,05. Dentre elas, a interação entre Dlic e Income foi a que mais se aproximou do limiar usual de significância, com $p = 0,141$. O coeficiente de determinação ajustado (R^2_{ajustado}) do modelo com interações foi de 0,5544, ligeiramente inferior ao valor obtido no modelo sem interações (modelo 5), cujo R^2 ajustado foi de 0,5677. Em termos do critério de informação de Akaike (AIC), observou-se uma pequena melhora: o valor passou de -70,21 no modelo sem interação para -71,88 no modelo com interações. Além disso, o teste F para comparação entre os modelos aninhados, realizado por meio da função `anova`, resultou em um p-valor de 0,0878. Esse resultado indica uma evidência fraca de que o modelo com interações apresenta um ajuste significativamente melhor em relação ao modelo sem interações, considerando o nível de significância convencional de 5%.

5 Conclusão

Com base nas análises realizadas, conclui-se que o modelo mais adequado para explicar a variável resposta $\log(\text{Fuel})$ que representa o consumo médio de gasolina por estado norte-americano, foi aquele que inclui como variáveis explicativas: Dlic (proporção de motoristas licenciados), Income (renda per capita), $\log(\text{Miles})$ (logaritmo das milhas rodadas) e Tax (taxa sobre a gasolina).

Diversos modelos foram ajustados e avaliados com base em critérios como o coeficiente de determinação ajustado (R^2_{ajustado}), o critério de informação de Akaike (AIC), a verificação das suposições do modelo de regressão linear múltipla e a análise de possíveis pontos aberrantes. Todos os modelos finalistas apresentaram bons ajustes e atenderam às

suposições fundamentais. No entanto, o modelo escolhido apresentou o maior R^2_{ajustado} , indicando melhor capacidade explicativa entre os candidatos, ainda que seu AIC não tenha sido o menor. Cabe destacar que o modelo com menor AIC não utilizava transformações nas variáveis, mas, ao aplicar o logaritmo na variável resposta e em uma das covariáveis, obteve-se uma melhor aderência aos pressupostos do modelo e uma interpretação mais adequada dos efeitos.

Por fim, a inclusão de interações de primeira ordem entre as covariáveis foi testada, mas não resultou em melhorias estatisticamente significativas no ajuste do modelo, o que reforça a adequação do modelo final com efeitos principais apenas.