



**Universidade de Brasília
Departamento de Estatística**

Lista Prática 1

Júlia Lima Nosralla

Relatório apresentado para a disciplina
Análise de Regressão Linear - EST0038
como parte dos requisitos necessários para
aprovação.

**Brasília
2025**

Sumário

1 Introdução	5
2 Análise Descritiva	6
2.1 Qualidade	6
2.2 Claridade	7
2.3 Aroma	8
2.4 Corpo	10
2.5 Sabor	11
2.6 Aroma do tonel de carvalho	12
3 Transformações e ajustes dos modelos de regressão linear simples	14
3.1 Qualidade pelo aroma	14
3.2 Qualidade pelo corpo	15
3.3 Qualidade pelo sabor.	17
4 Análise de diagnóstico	19
4.1 Normalidade dos erros	19
4.1.1 Qualidade pelo aroma	19
4.1.2 Qualidade pelo corpo	20
4.1.3 Qualidade pelo sabor	21
4.2 Homocedasticidade dos erros	23
4.2.1 Qualidade pelo aroma	23
4.2.2 Qualidade pelo corpo	24
4.2.3 Qualidade pelo sabor	25
4.3 Não correlação dos erros.	27
4.3.1 Qualidade pelo aroma	27
4.3.2 Qualidade pelo corpo	28
4.3.3 Qualidade pelo sabor	29
4.4 Alavancagem	30
4.4.1 Qualidade pelo aroma	30
4.4.2 Qualidade pelo corpo	31

4.5 Influência	31
4.5.1 Qualidade pelo aroma	32
4.5.2 Qualidade pelo corpo	32
5 Investigação de pontos atípicos.	33
5.1 Qualidade pelo aroma	34
5.2 Qualidade pelo corpo	34
6 Conclusão	35

1 Introdução

A análise estatística apresentada neste relatório tem como objetivo investigar os fatores que influenciam a qualidade do vinho com base em uma amostra de 38 vinhos da marca Pinot Noir. As variáveis disponíveis no conjunto de dados são: claridade, aroma, corpo, sabor e aroma do tonel de carvalho, que podem estar associadas à avaliação final de qualidade.

A proposta central deste estudo consiste em identificar o melhor modelo de regressão linear simples possível para explicar a qualidade do vinho com base em uma das demais variáveis do conjunto de dados. Inicialmente, será realizada uma análise descritiva das variáveis, utilizando medidas resumo e representações gráficas, a fim de compreender o comportamento dos dados. Em seguida, serão ajustados e avaliados diferentes modelos de regressão linear simples, verificando-se a adequação dos ajustes, o atendimento das suposições do modelo e a existência de pontos discrepantes que afetam os ajustes.

Por fim, será selecionado o modelo mais apropriado para explicar a qualidade do vinho, apresentando-se as interpretações dos resultados obtidos e a justificativa da escolha.

2 Análise Descritiva

Nesta seção, será realizada uma análise descritiva de cada variável com o objetivo de compreender o comportamento geral dos dados e de visualizar possíveis relações entre as covariáveis e a variável resposta.

2.1 Qualidade

Esta seção tem como objetivo analisar o comportamento da variável qualidade. Para isso, foram construídos um gráfico boxplot e uma tabela de medidas resumo, apresentados a seguir:




Figura 1: Boxplot da variável qualidade

Tabela 1: Medidas resumo da variável qualidade

Estatística	Valor
Média	12,44
Desvio-padrão	2,05
Mínimo	7,90
1º Quartil	11,15
Mediana	12,45
3º Quartil	13,75
Máximo	16,10

Com base na Figura 1 e na Tabela 1, a variável qualidade apresenta valores variando entre 7,90 e 16,10, com média de 12,44 e desvio-padrão de 2,05, o que indica uma dispersão moderada em torno da média. A mediana, com valor 12,45, é bastante próxima da média, sugerindo uma distribuição aproximadamente simétrica dos dados.

Os quartis mostram que 50% das observações estão concentradas entre 11,15 (1º quartil) e 13,75 (3º quartil), o que caracteriza uma dispersão moderada dos valores em torno da mediana. Ademais, o boxplot da Figura 1 não apresenta valores discrepantes.

2.2 Claridade

Esta seção tem como objetivo examinar o comportamento da variável claridade. Para isso, foram construídos um gráfico boxplot, um gráfico de dispersão com linha de regressão e uma tabela de medidas resumo, apresentados a seguir:




Figura 2: Boxplot da variável claridade




Figura 3: Gráfico de dispersão da qualidade pela claridade

Tabela 2: Medidas resumo da variável claridade

Estatística	Valor
Média	0,92
Desvio-padrão	0,12
Mínimo	0,50
1º Quartil	0,83
Mediana	1,00
3º Quartil	1,00
Máximo	1,00

A partir da Figura 2 e da Tabela 2, nota-se que a variável claridade apresenta valores variando entre 0,50 e 1,00, com média igual a 0,92 e desvio-padrão de 0,12, o que demonstra uma baixa dispersão dos dados em torno da média. Ademais, é possível observar que a maior parte dos valores se encontra próxima de 1,00, sugerindo que os vinhos avaliados possuem, em geral, alto nível de claridade.

O 3º quartil e a mediana são iguais a 1,00, o que implica que pelo menos 50% da amostra de vinhos possui a pontuação máxima de claridade. Dessa forma, os dados estão fortemente concentrados no limite superior da escala. Além disso, a mediana coincidir com o 3º quartil e o valor máximo, juntamente com o fato de a média (0,92) ser inferior à mediana (1,00), confirma uma acentuada assimetria negativa. Também vale ressaltar a presença de um valor mínimo isolado em 0,50, que pode ser observado tanto no boxplot da Figura 2 quanto no gráfico de dispersão apresentado na Figura 3. Portanto, a variável claridade apresenta uma distribuição altamente concentrada e assimétrica.

Por fim, a Figura 3 mostra que não há uma correlação significativa entre as variáveis claridade e qualidade, uma vez que a linha de regressão é praticamente horizontal. Isso se confirma com o cálculo do coeficiente de correlação de Pearson, que resulta em um valor pequeno, de 0,028. Dessa forma, a variável claridade não é a mais adequada para explicar a qualidade do vinho.

2.3 Aroma

Esta seção procura investigar o comportamento da variável aroma. Para isso, foram construídos um gráfico boxplot, um gráfico de dispersão com linha de regressão e uma tabela de medidas resumo, exibidos a seguir:




Figura 4: Boxplot da variável aroma




Figura 5: Gráfico de dispersão da qualidade pelo aroma

Tabela 3: Medidas resumo da variável aroma

Estatística	Valor
Média	4,85
Desvio-padrão	1,08
Mínimo	3,30
1º Quartil	4,13
Mediana	4,65
3º Quartil	5,45
Máximo	7,70

Com base na Figura 4 e na Tabela 3, observa-se que a variável aroma apresenta valores que variam entre 3,30 e 7,70, com média de 4,85 e desvio-padrão igual a 1,08, indicando uma dispersão moderada dos dados em torno da média. Além disso, os quartis mostram que metade das observações encontra-se entre 4,13 (1º quartil) e 5,45 (3º quartil).

O boxplot da Figura 4 evidencia uma distribuição com assimetria positiva, com

um valor atípico na extremidade superior. Ademais, a mediana (4,65) é ligeiramente inferior à média (4,85), o que reforça essa leve assimetria nos dados.

Por fim, a Figura 5 apresenta uma relação linear positiva entre as variáveis aroma e qualidade. É possível perceber que, à medida que o valor do aroma aumenta, a qualidade tende a crescer, o que é confirmado pela inclinação positiva da linha de regressão.

2.4 Corpo

Esta seção tem como objetivo estudar o comportamento da variável corpo. Para isso, foram construídos um gráfico boxplot, um gráfico de dispersão com linha de regressão e uma tabela de medidas resumo, expostos a seguir:




Figura 6: Boxplot da variável corpo




Figura 7: Gráfico de dispersão da qualidade pelo corpo

Tabela 4: Medidas resumo da variável corpo

Estatística	Valor
Média	4,68
Desvio-padrão	0,82
Mínimo	2,60
1º Quartil	4,15
Mediana	4,75
3º Quartil	5,38
Máximo	6,60

A Figura 6 e a Tabela 4 revelam que a variável corpo apresenta valores que variam entre 2,60 e 6,60, com média igual a 4,68 e desvio-padrão de 0,82, indicando uma dispersão moderada dos dados em torno da média. A mediana, de 4,75, é próxima da média, o que sugere uma distribuição quase simétrica. Além disso, o 1º quartil (4,15) e o 3º quartil (5,38) mostram que metade das observações está concentrada nesse intervalo. Ainda, vale notar que o boxplot da Figura 6 não possui pontos discrepantes.

Ademais, o gráfico de dispersão entre corpo e qualidade na Figura 7 evidencia uma relação linear positiva entre as variáveis, ou seja, à medida que os valores de corpo aumentam, os valores de qualidade também tendem a crescer.

2.5 Sabor

Esta seção busca analisar o comportamento da variável sabor. Para isso, foram construídos um gráfico boxplot, um gráfico de dispersão com linha de regressão e uma tabela de medidas resumo, exibidos a seguir:




Figura 8: Boxplot da variável sabor




Figura 9: Gráfico de dispersão da qualidade pelo sabor

Tabela 5: Medidas resumo da variável sabor

Estatística	Valor
Média	4,77
Desvio-padrão	1,03
Mínimo	2,90
1º Quartil	4,23
Mediana	4,80
3º Quartil	5,50
Máximo	7,00

A Figura 8 e a Tabela 5 mostram que a variável sabor apresenta média de 4,77 e desvio-padrão de 1,03, o que indica uma dispersão moderada em comparação com o valor médio. Os valores observados variam de 2,90 a 7,00, revelando uma amplitude considerável. Vale ressaltar que a mediana (4,80) é bastante próxima da média, de modo que a distribuição dos dados é aproximadamente simétrica. Além disso, observa-se que 50% das observações estão entre 4,23 (1º quartil) e 5,50 (3º quartil). Ainda, nota-se que o boxplot da Figura 8 não possui valores discrepantes.

Ademais, a Figura 9 evidencia uma relação linear positiva entre as variáveis, ou seja, à medida que a nota de sabor aumenta, a qualidade tende a aumentar também.

2.6 Aroma do tonel de carvalho

Esta seção procura examinar o comportamento da variável aroma do tonel de carvalho. Para isso, foram construídos um gráfico boxplot, um gráfico de dispersão com linha de regressão e uma tabela de medidas resumo, apresentados a seguir:




Figura 10: Boxplot da variável aroma do tonel de carvalho




Figura 11: Gráfico de dispersão da qualidade pelo aroma do tonel de carvalho

Tabela 6: Medidas resumo da variável aroma do tonel de carvalho

Estatística	Valor
Média	4,26
Desvio-padrão	0,74
Mínimo	2,90
1º Quartil	3,70
Mediana	4,10
3º Quartil	4,78
Máximo	6,00

Com base na Figura 10 e na Tabela 6, nota-se que a variável sabor apresenta valores variando entre 2,90 e 6,00, com média igual a 4,26 e desvio-padrão de 0,74, indicando uma dispersão moderada dos dados em torno da média. Observa-se que a mediana é 4,10, valor ligeiramente inferior à média, o que sugere uma leve assimetria positiva na distribuição da variável. Ademais, os quartis mostram que 50% das observações estão con-

centradas entre 3,70 (1º quartil) e 4,78 (3º quartil). Ainda, vale ressaltar que o boxplot da Figura 10 não possui valores discrepantes.

Por fim, a Figura 11 mostra que não há uma correlação significativa entre as variáveis aroma do tonel de carvalho e qualidade, uma vez que a linha de regressão é praticamente horizontal. Isso se confirma com o cálculo do coeficiente de correlação de Pearson, que resulta em um valor pequeno, de -0,047. Dessa forma, a variável aroma do tonel de carvalho não é a mais adequada para explicar a qualidade do vinho.

3 Transformações e ajustes dos modelos de regressão linear simples

Nesta seção, são apresentados os ajustes dos modelos de regressão utilizando as variáveis em suas formas originais e as variáveis transformadas. O objetivo é comparar o desempenho dos modelos e verificar se as transformações aplicadas contribuem para a melhoria dos pressupostos de regressão, tais como normalidade dos erros, homocedasticidade e linearidade entre as variáveis.

3.1 Qualidade pelo aroma

Nesta seção, são ajustados dois modelos para as variáveis aroma e qualidade: um utilizando as variáveis originais e outro com transformação logarítmica na variável resposta. A comparação entre os modelos será realizada por meio de gráficos de dispersão e de medidas resumo das estatísticas de ajuste, buscando identificar possíveis melhorias após a transformação.




Figura 12: Gráfico de dispersão com variáveis originais




Figura 13: Gráfico de dispersão com transformação logarítmica na variável qualidade

No modelo sem transformação, demonstrado pela Figura 12, observa-se uma tendência linear positiva, ou seja, vinhos mais aromáticos tendem a apresentar maior qualidade. Contudo, nota-se que há uma dispersão considerável dos pontos em torno da

reta.

Já na Figura 13, o gráfico com a variável transformada mostra que a relação linear é mantida. Além disso, a dispersão dos pontos ao longo da linha de regressão é menor, sugerindo um ajuste mais consistente em comparação ao modelo sem transformação.

Tabela 7: Medidas resumo do modelo sem transformação

Estatística	Valor
Intercepto (β_0)	5,9583
Erro Padrão do Intercepto	1,1050
Coefficiente (β_1)	1,3365
Erro Padrão do Coeficiente	0,2226
R^2	0,5003
R^2 Ajustado	0,4864
Erro Padrão Residual	1,4660
P-valor do Modelo	$6,87 \times 10^{-7}$

Tabela 8: Medidas resumo do modelo com transformação logarítmica na variável qualidade

Estatística	Valor
Intercepto (β_0)	1,9883
Erro Padrão do Intercepto	0,0971
Coefficiente (β_1)	0,1070
Erro Padrão do Coeficiente	0,0200
R^2	0,4536
R^2 Ajustado	0,4384
Erro Padrão Residual	0,1288
P-valor do Modelo	$3,59 \times 10^{-6}$

Com base na Tabela 7, o modelo ajustado sem transformações apresentou um intercepto de $\beta_0 = 5,9583$, um coeficiente angular de $\beta_1 = 1,3365$ e um coeficiente de determinação $R^2 = 0,5003$, indicando que aproximadamente 50,03% da variabilidade da qualidade do vinho é explicada pela variável aroma. O erro padrão residual foi de 1,466, sugerindo uma dispersão moderada dos resíduos.

O segundo modelo, exibido na Tabela 8, apresentou um intercepto de $\beta_0 = 1,9883$, um coeficiente angular de $\beta_1 = 0,107$ e um coeficiente de determinação $R^2 = 0,4536$. Apesar de ligeiramente menor, o ajuste continua explicando uma porção substancial da variabilidade. O erro padrão residual foi reduzido para 0,1288.

3.2 Qualidade pelo corpo

Nesta seção, foram ajustados dois modelos para as variáveis corpo e qualidade, considerando-as em sua forma original e com transformação logarítmica na variável resposta. Para ilustrar os resultados, foram elaborados gráficos de dispersão e tabelas com as principais medidas de ajuste.




Figura 14: Gráfico de dispersão com variáveis originais




Figura 15: Gráfico de dispersão com transformação logarítmica na variável qualidade

A partir da Figura 14, é possível perceber que o modelo ajustado demonstra uma relação linear positiva, indicando que vinhos mais encorpados possuem mais qualidade. Ademais, nota-se uma certa dispersão dos pontos em torno da linha.

Já na Figura 15, observa-se que a relação linear positiva se mantém, além de haver uma leve diminuição na dispersão dos pontos ao longo da reta.

Tabela 9: Medidas resumo do modelo sem transformação

Estatística	Valor
Intercepto (β_0)	6,0580
Erro Padrão do Intercepto	1,6441
Coeficiente (β_1)	1,3618
Erro Padrão do Coeficiente	0,3458
R^2	0,3011
R^2 Ajustado	0,2817
Erro Padrão Residual	1,7340
P-valor do Modelo	$3,61 \times 10^{-4}$

Tabela 10: Medidas resumo do modelo com transformação logarítmica na variável qualidade

Estatística	Valor
Intercepto (β_0)	1,9913
Erro Padrão do Intercepto	0,1404
Coeficiente (β_1)	0,1101
Erro Padrão do Coeficiente	0,0295
R^2	0,2784
R^2 Ajustado	0,2583
Erro Padrão Residual	0,1480
P-valor do Modelo	$6,64 \times 10^{-4}$

Com base na Tabela 9, o modelo ajustado sem transformações apresentou um intercepto de $\beta_0 = 6,058$, um coeficiente angular de $\beta_1 = 1,3618$ e um coeficiente de determinação $R^2 = 0,3011$, indicando que apenas 30,11% da variabilidade da qualidade do vinho é explicada pela variável corpo. O erro padrão residual foi de 1,734, sugerindo uma dispersão moderada dos resíduos.

O segundo modelo, apresentado na Tabela 10, apresentou um intercepto de $\beta_0 = 1,9913$, um coeficiente angular de $\beta_1 = 0,1101$ e um coeficiente de determinação $R^2 = 0,2784$. O erro padrão residual foi reduzido para 0,148. Além disso, os coeficientes de determinação baixos em ambos os modelos sugerem que outras variáveis podem ser mais relevantes para explicar a variabilidade da qualidade.

3.3 Qualidade pelo sabor

Nesta seção, são ajustados três modelos para as variáveis sabor e qualidade: um utilizando as variáveis originais, um com transformação logarítmica na variável resposta e outro com transformação raiz quadrada na variável resposta. A comparação entre os modelos será realizada por meio de gráficos de dispersão e de medidas resumo das estatísticas de ajuste, buscando identificar possíveis melhorias após a transformação.




Figura 16: Gráfico de dispersão com variáveis originais




Figura 17: Gráfico de dispersão com transformação logarítmica na variável qualidade




Figura 18: Gráfico de dispersão com transformação raiz quadrada na variável qualidade

No modelo sem transformação, ilustrado pela Figura 16, percebe-se uma tendência linear positiva, ou seja, vinhos com maior nota de sabor tendem a apresentar maior qualidade. No entanto, é possível observar que a dispersão dos pontos em torno da reta diminui para os valores mais altos da variável sabor.

Na Figura 17, o gráfico com a transformação logarítmica mostra que a relação entre as variáveis se mantém linear, com a dispersão dos pontos mais constante ao longo da reta de regressão. Assim, há uma leve melhora na homogeneidade dos resíduos.

Por fim, a transformação raiz quadrada, demonstrada pelo gráfico da Figura 18, também apresenta boa linearidade e menor dispersão que o gráfico sem transformação, contribuindo para uma leve estabilização da variância.

Tabela 11: Medidas resumo do modelo sem transformação

Estatística	Valor
Intercepto (β_0)	4,9414
Erro Padrão do Intercepto	0,9911
Coeficiente (β_1)	1,5719
Erro Padrão do Coeficiente	0,2033
R^2	0,6242
R^2 Ajustado	0,6137
Erro Padrão Residual	1,2710
P-valor do Modelo	$3,68 \times 10^{-9}$

Tabela 12: Medidas resumo do modelo com transformação logarítmica na variável qualidade

Estatística	Valor
Intercepto (β_0)	1,8859
Erro Padrão do Intercepto	0,0853
Coeficiente (β_1)	0,1302
Erro Padrão do Coeficiente	0,0175
R^2	0,6062
R^2 Ajustado	0,5953
Erro Padrão Residual	0,1094
P-valor do Modelo	$8,64 \times 10^{-9}$

Tabela 13: Medidas resumo do modelo com transformação raiz quadrada na variável qualidade

Estatística	Valor
Intercepto (β_0)	2,4395
Erro Padrão do Intercepto	0,1444
Coeficiente (β_1)	0,2254
Erro Padrão do Coeficiente	0,0296
R^2	0,6168
R^2 Ajustado	0,6061
Erro Padrão Residual	0,1852
P-valor do Modelo	$5,26 \times 10^{-9}$

Com base na Tabela 11, o modelo ajustado sem transformações apresentou um intercepto de $\beta_0 = 4,9414$, um coeficiente angular de $\beta_1 = 1,5719$ e um coeficiente de determinação $R^2 = 0,6242$, indicando que aproximadamente 62,42% da variabilidade da qualidade do vinho é explicada pela variável sabor. O erro padrão residual foi de 1,271, sugerindo uma dispersão moderada dos resíduos.

O segundo modelo, mostrado na Tabela 12, apresentou um intercepto de $\beta_0 = 1,8859$ e um coeficiente angular de $\beta_1 = 0,1302$. O coeficiente de determinação R^2 , com valor de 0,6062, permaneceu praticamente igual ao modelo original, indicando que a transformação não alterou substancialmente a capacidade explicativa. O erro padrão residual foi reduzido para 0,1094.

A Tabela 13, que expõe as medidas do modelo com transformação raiz quadrada, apresentou um intercepto de $\beta_0 = 2,4395$, um coeficiente angular de $\beta_1 = 0,2254$ e um coeficiente de determinação $R^2 = 0,6168$, semelhante ao modelo original. O erro padrão

residual obtido foi igual a 0,1852.

Vale ressaltar que os modelos ajustados com a variável sabor resultaram em coeficientes de determinação com valores mais altos em relação aos modelos ajustados com as variáveis aroma e corpo.

4 Análise de diagnóstico

A análise de diagnóstico busca avaliar a adequação do modelo e identificar possíveis violações das hipóteses de normalidade, homocedasticidade e independência dos erros. Dessa forma, esta seção tem como objetivo verificar se as suposições básicas dos modelos lineares ajustados foram atendidas, garantindo a validade das inferências realizadas. Além disso, essa etapa permite detectar observações influentes ou valores discrepantes que possam impactar de forma significativa nos resultados do ajuste.

4.1 Normalidade dos erros

A suposição de normalidade dos erros é essencial para que as inferências estatísticas no modelo de regressão linear sejam válidas. Essa hipótese pressupõe que os erros do modelo seguem uma distribuição normal com média zero. A verificação dessa condição será realizada por meio da análise dos gráficos de envelope simulado das distribuições normal e t-student para cada um dos modelos ajustados na Seção 3.

4.1.1 Qualidade pelo aroma

As figuras a seguir apresentam os gráficos de envelope simulado das distribuições normal e t-student para os modelos ajustados com as variáveis qualidade e aroma.




Figura 19: Gráfico de envelope da normal com variáveis originais




Figura 20: Gráfico de envelope da normal com transformação logarítmica na variável qualidade




Figura 21: Gráfico de envelope da t-student com variáveis originais




Figura 22: Gráfico de envelope da t-student com transformação logarítmica na variável qualidade

As Figuras 19, 20, 21 e 22 não apresentam desvios graves contra a suposição de normalidade. Em ambos os modelos, observa-se que os pontos seguem razoavelmente a linha de referência, com pequenas discrepâncias, sobretudo nas extremidades. Assim, a maior parte dos resíduos encontra-se dentro do envelope, indicando que os modelos atendem ao pressuposto.

4.1.2 Qualidade pelo corpo

As figuras a seguir apresentam os gráficos de envelope simulado das distribuições normal e t-student para os modelos ajustados com as variáveis qualidade e corpo.




Figura 23: Gráfico de envelope da normal com variáveis originais




Figura 24: Gráfico de envelope da normal com transformação logarítmica na variável qualidade




Figura 25: Gráfico de envelope da t-student com variáveis originais




Figura 26: Gráfico de envelope da t-student com transformação logarítmica na variável qualidade

As Figuras 23 e 25 mostram que o modelo sem transformação não apresenta desvios graves em relação à suposição de normalidade. Embora sejam visíveis alguns pontos discrepantes, a maioria das observações se encontra dentro dos envelopes. Ademais, é possível observar uma adequação superior para o gráfico de envelope com distribuição t-student, na Figura 25. Portanto, o pressuposto de normalidade dos erros é atendido para o modelo.

Já para o modelo com transformação logarítmica, é possível perceber uma quantidade maior de pontos fora do envelope, tanto no gráfico ilustrado na Figura 24 quanto no gráfico representado pela Figura 26. Desse modo, o modelo com transformação logarítmica não atende ao pressuposto de normalidade dos erros.

4.1.3 Qualidade pelo sabor

As figuras a seguir apresentam os gráficos de envelope simulado das distribuições normal e t-student para os modelos ajustados com as variáveis qualidade e sabor.




Figura 27: Gráfico de envelope da normal com variáveis originais




Figura 28: Gráfico de envelope da normal com transformação logarítmica




Figura 29: Gráfico de envelope da normal com transformação raiz quadrada




Figura 30: Gráfico de envelope da t-student com variáveis originais




Figura 31: Gráfico de envelope da t-student com transformação logarítmica na variável qualidade




Figura 32: Gráfico de envelope da t-student com transformação raiz quadrada na variável qualidade

Nas figuras acima, nota-se que, embora alguns pontos estejam fora dos envelopes, a maior parte dos pontos segue razoavelmente as bandas de confiança. É possível perceber uma adequação ligeiramente superior nos gráficos de envelope para a distribuição t-student, representados nas Figuras 30, 31 e 32, com os pontos mais concentrados dentro dos envelopes. Portanto, o pressuposto de normalidade dos erros é atendido para os modelos.

Além disso, as Figuras 28 e 31, referentes à transformação logarítmica, mostram melhor aderência dos resíduos à linha teórica em comparação aos outros dois modelos, sugerindo que a transformação contribui para aproximar os erros de uma distribuição normal.

4.2 Homocedasticidade dos erros

A verificação do pressuposto de homocedasticidade é fundamental na análise de regressão para garantir que a variabilidade dos resíduos permaneça constante ao longo dos valores ajustados. Nesta seção, são apresentados os gráficos de dispersão dos resíduos pelos valores ajustados e testes de hipóteses para cada modelo que atendeu à suposição de normalidade, testada anteriormente. Com isso, procura-se identificar possíveis padrões que indiquem variância não constante.

4.2.1 Qualidade pelo aroma

As figuras a seguir mostram os gráficos de dispersão dos resíduos pelos valores ajustados para os modelos com as variáveis qualidade e aroma. Para complementar a avaliação gráfica, também será realizado o teste de hipóteses de Goldfeld-Quandt.




Figura 33: Gráfico dos resíduos pelos valores ajustados com variáveis originais




Figura 34: Gráfico dos resíduos pelos valores ajustados com transformação logarítmica na variável qualidade

Nos gráficos apresentados nas Figuras 33 e 34, não é possível identificar nenhum padrão na distribuição dos pontos ao longo do eixo dos valores ajustados, ou seja, não há desvios severos em relação à suposição de homocedasticidade. Para reforçar a análise gráfica, foi realizado o teste de hipóteses de Goldfeld-Quandt. As hipóteses a serem testadas são:

$$\begin{cases} H_0 : \text{Os erros do modelo possuem variância constante.} \\ H_1 : \text{Os erros do modelo não possuem variância constante.} \end{cases}$$

A tabela a seguir exhibe os resultados do teste considerando-se o nível de significância $\alpha = 0,05$.

Tabela 14: Resultados do teste de Goldfeld-Quandt para verificação da homocedasticidade

Modelo	p-valor	Decisão
$qualidade \sim aroma$	0,3699	Não rejeita a hipótese nula
$\log(qualidade) \sim aroma$	0,09917	Não rejeita a hipótese nula

Os resultados apresentados na Tabela 14 indicam que, para ambos os modelos, os valores de p são superiores ao nível de significância de 5%. Dessa forma, não há evidências para rejeitar a hipótese nula de homocedasticidade, sugerindo que a variância dos erros pode ser considerada constante para os modelos.

4.2.2 Qualidade pelo corpo

A figura a seguir mostra o gráfico de dispersão dos resíduos pelos valores ajustados para o modelo com as variáveis qualidade e corpo. Para complementar a avaliação gráfica, também será realizado o teste de hipóteses de Goldfeld-Quandt.




Figura 35: Gráfico dos resíduos pelos valores ajustados com variáveis originais

Com base na Figura 35, não é possível identificar nenhum padrão na distribuição dos pontos ao longo do eixo dos valores ajustados. A ausência de padrões sistemáticos indica que não há evidências fortes de heterocedasticidade. Para complementar a análise gráfica, foi feito o teste de hipótese de Goldfeld-Quandt, que avalia as seguintes hipóteses:

$$\begin{cases} H_0 : \text{Os erros do modelo possuem variância constante.} \\ H_1 : \text{Os erros do modelo não possuem variância constante.} \end{cases}$$

A tabela a seguir exhibe os resultados do teste considerando-se o nível de significância $\alpha = 0,05$.

Tabela 15: Resultados do teste de Goldfeld-Quandt para verificação da homocedasticidade

Modelo	p-valor	Decisão
$qualidade \sim corpo$	0,4802	Não rejeita a hipótese nula

Os resultados apresentados na Tabela 15 indicam que o valor de p encontrado é superior ao nível de significância de 5%. Dessa forma, não há evidências para rejeitar a hipótese nula de homocedasticidade, sugerindo que a variância dos erros pode ser considerada constante para o modelo.

4.2.3 Qualidade pelo sabor

As figuras a seguir mostram os gráficos de dispersão dos resíduos pelos valores ajustados para os modelos com as variáveis qualidade e sabor. Para complementar a avaliação gráfica, também será realizado o teste de hipóteses de Goldfeld-Quandt.




Figura 36: Gráfico dos resíduos pelos valores ajustados com variáveis originais




Figura 37: Gráfico dos resíduos pelos valores ajustados com transformação logarítmica na variável qualidade




Figura 38: Gráfico dos resíduos pelos valores ajustados com transformação raiz quadrada na variável qualidade

As Figuras 36, 37 e 38 revelam uma discreta redução na dispersão dos resíduos à medida que os valores ajustados aumentam, o que indica um possível problema em relação à homocedasticidade dos modelos. Para reforçar a análise gráfica, foi feito o teste de hipótese de Goldfeld-Quandt, que avalia as seguintes hipóteses:

$$\begin{cases} H_0 : \text{Os erros do modelo possuem variância constante,} \\ H_1 : \text{Os erros do modelo não possuem variância constante.} \end{cases}$$

A tabela a seguir exhibe os resultados do teste considerando-se o nível de significância $\alpha = 0,05$.

Tabela 16: Resultados do teste de Goldfeld-Quandt para verificação da homocedasticidade

Modelo	p-valor	Decisão
$qualidade \sim sabor$	0,1045	Não rejeita a hipótese nula
$\log(qualidade) \sim sabor$	0,0153	Rejeita a hipótese nula
$\sqrt{qualidade} \sim sabor$	0,0429	Rejeita a hipótese nula

Os resultados apresentados na Tabela 16 indicam que apenas o modelo com as variáveis originais apresentou um p -valor superior ao nível de significância de 5%. Dessa forma, a suposição de homocedasticidade não é atendida para os modelos com transformação logarítmica e raiz quadrada.

4.3 Não correlação dos erros

A suposição de não correlação dos erros garante que a informação contida em uma observação não esteja influenciando diretamente outra, evitando vieses nos estimadores dos coeficientes do modelo e garantindo a validade das inferências estatísticas. Nesta seção, a adequação ao pressuposto será avaliada por meio de métodos gráficos e testes de hipóteses aplicados nos modelos ajustados que atenderam às suposições testadas anteriormente.

4.3.1 Qualidade pelo aroma

As figuras a seguir mostram os gráficos de dispersão dos resíduos pelos índices das observações para os modelos com as variáveis qualidade e aroma. A fim de complementar a avaliação gráfica, também será realizado o teste de hipóteses de Durbin-Watson.




Figura 39: Gráfico dos resíduos pelos índices com variáveis originais




Figura 40: Gráfico dos resíduos pelos índices com transformação logarítmica na variável qualidade

Analisando as Figuras 39 e 40, os resíduos não se distribuem de maneira uniforme ao longo dos índices. É possível perceber um certo padrão entre os resíduos, que é ligeiramente mais suave na Figura 40. Para complementar a análise gráfica, será realizado o teste de Durbin-Watson, que avalia as seguintes hipóteses:

$$\begin{cases} H_0 : \text{Não há autocorrelação entre os erros.} \\ H_1 : \text{Há autocorrelação entre os erros.} \end{cases}$$

A tabela a seguir exhibe os resultados do teste considerando-se o nível de significância $\alpha = 0,05$.

Tabela 17: Resultados do teste de Durbin-Watson para verificação da autocorrelação dos erros

Modelo	p-valor	Decisão
$qualidade \sim aroma$	0,0416	Rejeita a hipótese nula
$\log(qualidade) \sim aroma$	0,0693	Não rejeita a hipótese nula

Os resultados apresentados na Tabela 17 indicam que apenas o modelo com transformação logarítmica apresentou um p -valor superior ao nível de significância de 5%. Dessa forma, a suposição de não correlação dos erros não é atendida para o modelo com as variáveis originais.

4.3.2 Qualidade pelo corpo

A figura a seguir apresenta o gráfico de dispersão dos resíduos pelos índices das observações para o modelo com as variáveis qualidade e corpo. A fim de complementar a avaliação gráfica, também será realizado o teste de hipóteses de Durbin-Watson.




Figura 41: Gráfico dos resíduos pelos valores ajustados com variáveis originais

A Figura 41 não mostra desvios graves contra a suposição de não correlação, embora seja possível identificar um leve padrão nos pontos ao longo dos índices. Para complementar a análise gráfica, será aplicado o teste de Durbin-Watson. As hipóteses a serem testadas são:

$$\begin{cases} H_0 : \text{Não há autocorrelação entre os erros.} \\ H_1 : \text{Há autocorrelação entre os erros.} \end{cases}$$

A tabela a seguir exibe os resultados do teste considerando-se o nível de signi-

ficância $\alpha = 0,05$.

Tabela 18: Resultados do teste de Durbin-Watson para verificação da autocorrelação dos erros

Modelo	p-valor	Decisão
$qualidade \sim corpo$	0,1931	Não rejeita a hipótese nula

Os resultados apresentados na Tabela 18 indicam que o valor de p encontrado é superior ao nível de significância de 5%. Desse modo, não há evidências para rejeitar a hipótese nula de ausência de autocorrelação entre os erros.

4.3.3 Qualidade pelo sabor

A figura a seguir mostra o gráfico de dispersão dos resíduos pelos índices das observações para o modelo com as variáveis qualidade e sabor. A fim de complementar a avaliação gráfica, também será realizado o teste de hipóteses de Durbin-Watson.




Figura 42: Gráfico dos resíduos pelos índices com variáveis originais

Com base na Figura 42, os resíduos não se distribuem uniformemente ao longo dos índices, sendo possível perceber um padrão claro entre os pontos. Para reforçar a análise gráfica, será realizado o teste de Durbin-Watson, que avalia as seguintes hipóteses:

$$\begin{cases} H_0 : \text{Não há autocorrelação entre os erros.} \\ H_1 : \text{Há autocorrelação entre os erros.} \end{cases}$$

A tabela a seguir exibe os resultados do teste considerando-se o nível de signi-

ficância $\alpha = 0,05$.

Tabela 19: Resultados do teste de Durbin-Watson para verificação da autocorrelação dos erros

Modelo	p-valor	Decisão
$qualidade \sim sabor$	0,0003	Rejeita a hipótese nula

Os resultados apresentados na Tabela 19 revelam que o modelo apresenta um p -valor inferior ao nível de significância de 5%, rejeitando a hipótese nula. Dessa forma, a suposição de não correlação dos erros não foi atendida.

4.4 Alavancagem

Nesta seção, será avaliada a presença de pontos de alavancagem nos modelos de regressão que atenderam aos pressupostos de normalidade, homocedasticidade e não correlação dos erros. A alavancagem tem como objetivo identificar observações que podem exercer forte influência sobre o ajuste do modelo em função de sua posição nas variáveis explicativas. Para essa análise, será utilizado o gráfico da medida h , que representa a alavancagem, pelos índices das observações. Os limites adotados para interpretação foram $4/n$ e $6/n$, onde n representa o número total de observações. Pontos com valores de alavancagem superiores a $4/n$ indicam uma influência moderada, enquanto aqueles acima de $6/n$ são considerados altamente influentes, podendo impactar de maneira significativa as estimativas do modelo.

4.4.1 Qualidade pelo aroma

A figura a seguir apresenta o gráfico da medida de alavancagem (h) em função dos índices das observações para o modelo ajustado com as variáveis $\log(\text{qualidade})$ e aroma.




Figura 43: Gráfico de alavancagem com transformação logarítmica na variável qualidade

A Figura 43 revela três pontos (14, 15 e 34) que possuem uma alavancagem significativamente maior do que o restante das observações. O ponto 14 excede a linha vermelha, indicando uma alavancagem alta, enquanto os pontos 15 e 34, que se encontram entre a linha azul e a linha vermelha, podem apresentar uma alavancagem moderada. Tais pontos devem ser investigados posteriormente.

4.4.2 Qualidade pelo corpo

A figura a seguir apresenta o gráfico da medida de alavancagem (h) em função dos índices das observações para o modelo ajustado com as variáveis qualidade e corpo.




Figura 44: Gráfico de alavancagem com variáveis originais

A Figura 44 revela três pontos (1, 4 e 14) que possuem uma alavancagem significativamente maior do que o restante das observações. Todos os pontos mencionados excedem a linha vermelha, indicando uma alavancagem alta. Tais observações devem ser investigadas posteriormente.

4.5 Influência

Nesta seção, será avaliada a presença de observações influentes nos modelos de regressão que atenderam aos pressupostos de normalidade, homocedasticidade e não correlação dos erros. A análise de influência busca identificar pontos que exercem impacto significativo sobre os parâmetros estimados do modelo de regressão. Essas observações podem distorcer as estimativas dos coeficientes, alterar medidas de ajuste e comprometer as conclusões do modelo. Dessa forma, serão utilizadas medidas como a Distância de Cook, DFFITS e DFBETAS a fim de identificar a presença de pontos influentes nos modelos.

4.5.1 Qualidade pelo aroma

As figuras a seguir têm como objetivo identificar possíveis pontos influentes no modelo ajustado para as variáveis $\log(\text{qualidade})$ e aroma.




Figura 45: Gráfico da distância de Cook com transformação logarítmica na variável qualidade




Figura 46: Gráfico de DFFITS com transformação logarítmica na variável qualidade




Figura 47: Gráfico de DFBETAS para o intercepto com transformação logarítmica na variável qualidade




Figura 48: Gráfico de DFBETAS para o coef. angular com transformação logarítmica na variável qualidade

Com base nas Figuras 45, 46, 47 e 48, nota-se que o ponto 20 é a observação que mais se destaca em todas as métricas, indicando uma possível influência na estimativa de todos os coeficientes do modelo e no valor predito. Os pontos 12, 30 e 33 também ultrapassam os limiares estabelecidos e, portanto, merecem atenção.

4.5.2 Qualidade pelo corpo

As figuras a seguir têm como objetivo identificar possíveis pontos influentes no modelo ajustado para as variáveis qualidade e corpo.




Figura 49: Gráfico da distância de Cook com variáveis originais




Figura 50: Gráfico de DFFITS com variáveis originais




Figura 51: Gráfico de DFBETAS para o intercepto com variáveis originais




Figura 52: Gráfico de DFBETAS para o coef. angular com variáveis originais

A partir das Figuras 49 e 50, é possível perceber que o ponto 20 se destaca para as medidas da distância de Cook e DFFITS. O ponto 4 é altamente influente nos coeficientes individuais, como pode ser observado nas Figuras 51 e 52, e também no valor ajustado (DFFITS), apresentado na Figura 50. Além disso, o ponto 37 excede os limiares estabelecidos para as medidas DFFITS e DFBETAS para o coeficiente angular, e a observação 30 ultrapassa o limite determinado para a métrica DFBETAS do intercepto. Assim, é essencial investigar esses quatro pontos (4, 20, 30 e 37).

5 Investigação de pontos atípicos

Nesta seção serão investigados os pontos destacados nas análises de alavancagem e de influência. Essa investigação será realizada por meio da retirada desses pontos de maneira individual e conjunta, com o objetivo de avaliar o impacto nas estatísticas do modelo e a existência de mudanças inferenciais.

5.1 Qualidade pelo aroma

Para o modelo com as variáveis $\log(\text{qualidade})$ e aroma, as observações com mais destaque nas medidas de influência e alavancagem foram os pontos 12, 14, 15, 20, 30, 33 e 34. A tabela com as mudanças relativas nos coeficientes do modelo ao realizar a retirada de cada ponto é apresentada a seguir:

Tabela 20: Estimativas do modelo com transformação logarítmica na variável qualidade retirando os pontos atípicos

Pontos	β_0	Mudança em β_0	β_1	Mudança em β_1
Com todos os pontos	1,98832	0%	0,10695	0%
Retirando o ponto 12	1,95178	-1,84%	0,11349	6,12%
Retirando o ponto 14	1,97603	-0,62%	0,10971	-0,62%
Retirando o ponto 15	1,98652	-0,09%	0,10736	-0,39%
Retirando o ponto 20	2,04628	2,92%	0,09667	-9,62%
Retirando o ponto 30	2,01043	1,11%	0,10423	-2,54%
Retirando o ponto 33	1,95534	-1,66%	0,11286	5,55%
Retirando o ponto 34	1,98520	-0,16%	0,10770	0,68%
Retirando os pontos 12, 14, 15, 20, 30, 33 e 34	1,96710	-1,07%	0,11374	6,35%

Analisando a Tabela 20, verifica-se que a exclusão dos pontos 12 e 33 provoca um aumento de aproximadamente 5 a 6% na estimativa do coeficiente angular, indicando que essas observações exercem influência moderada sobre a inclinação da reta de regressão. Por outro lado, o ponto 20 se destaca como o mais influente, uma vez que sua remoção resulta em um aumento de 2,92% no intercepto e uma redução de 9,62% no coeficiente angular.

Os demais pontos (14, 15, 30 e 34) produzem alterações inferiores a 3% nos coeficientes, o que indica baixa influência individual. Quando todos os pontos identificados (12, 14, 15, 20, 30, 33 e 34) são removidos simultaneamente, observa-se uma variação de apenas -1,07% no intercepto e de +6,35% na inclinação, o que evidencia que a forma geral do modelo permanece pouco alterada. Ainda, vale ressaltar que não ocorreram mudanças inferenciais em relação aos p -valores do modelo com a retirada dos pontos.

5.2 Qualidade pelo corpo

Para o modelo com as variáveis qualidade e corpo, as observações com mais destaque nas medidas de influência e alavancagem foram os pontos 1, 4, 14, 15, 20, 30 e 37. A tabela com as mudanças relativas nos coeficientes do modelo ao realizar a retirada de cada ponto é apresentada a seguir:

Tabela 21: Estimativas do modelo com variáveis originais retirando os pontos atípicos

Pontos	β_0	Mudança em β_0	β_1	Mudança em β_1
Com todos os pontos	6,0580	0%	1,3618	0%
Retirando o ponto 1	6,0902	0,53%	1,3554	-0,47%
Retirando o ponto 4	5,2803	-12,84%	1,5173	11,42%
Retirando o ponto 14	6,4790	6,96%	1,2650	-7,13%
Retirando o ponto 15	5,7761	-4,65%	1,4020	2,95%
Retirando o ponto 20	5,8913	-2,75%	1,4261	4,73%
Retirando o ponto 30	6,6405	9,61%	1,2530	-7,99%
Retirando o ponto 37	5,6269	-7,12%	1,4731	8,17%
Retirando os pontos 1, 4, 14, 15, 20, 30, e 37	4,8728	-19,56%	1,6441	20,73%

Com base na Tabela 21, é possível notar que o ponto 4 exerce a maior influência sobre o modelo, uma vez que sua remoção resulta em uma redução de 12,84% no intercepto e um aumento de 11,42% na inclinação. Os pontos 14 e 30 também se destacam, com variações de aproximadamente 7% a 10% em ambos os coeficientes. Já os pontos 15, 20 e 37 provocam alterações moderadas (entre 3% e 8%), enquanto o ponto 1 apresenta influência baixa.

Quando todos os pontos identificados (1, 4, 14, 15, 20, 30 e 37) são removidos simultaneamente, observa-se uma redução de 19,56% no intercepto e um aumento de 20,73% no coeficiente angular. Dessa forma, conclui-se que o modelo apresenta sensibilidade à presença de pontos influentes.

6 Conclusão

A partir das análises discutidas neste relatório, conclui-se que o melhor modelo de regressão linear simples ajustado foi o modelo $\log(\text{qualidade}) \sim \text{aroma}$. Embora apresente um R^2 moderado, com valor igual a 45%, esse modelo atendeu adequadamente às suposições e demonstrou uma baixa sensibilidade em relação à presença de pontos atípicos, indicando que as estimativas do ajuste são mais confiáveis e estáveis.

Com o intuito de interpretar o modelo selecionado de forma mais detalhada, segue a tabela com as respectivas estatísticas de ajuste:

Tabela 22: Medidas resumo do modelo $\log(\text{qualidade}) \sim \text{aroma}$

Estatística	Valor
Intercepto (β_0)	1,9883
Erro Padrão do Intercepto	0,0971
Coeficiente (β_1)	0,1070
Erro Padrão do Coeficiente	0,0200
R^2	0,4536
R^2 Ajustado	0,4384
Erro Padrão Residual	0,1288
P-valor do Modelo	$3,59 \times 10^{-6}$

Ao examinar com mais detalhe o modelo ajustado, observa-se que o intercepto ($\beta_0 = 1,9883$) corresponde ao valor esperado do logaritmo da qualidade quando a variável aroma é igual a zero. Já o coeficiente angular ($\beta_1 = 0,107$) revela que, a cada incremento de uma unidade na covariável, estima-se um aumento de 0,107 unidades na média do logaritmo da qualidade.

Por fim, foi construído o intervalo de confiança de 95% para os coeficientes do modelo selecionado. O resultado está exposto na tabela a seguir:

Tabela 23: Intervalos de confiança dos coeficientes do modelo $\log(\text{qualidade}) \sim \text{aroma}$

Coeficiente	Limite inferior	Limite superior
Intercepto (β_0)	1,7914	2,1853
Coeficiente (β_1)	0,0673	0,1466

Com base na Tabela 23, ambos os intervalos de confiança não contêm o zero, indicando que tanto o intercepto quanto o coeficiente angular são estatisticamente significativos ao nível de 5%.